

学校编码: 10384

学 号:

厦門大學

硕 士 学 位 论 文

基于局部信息结构增强和图对比学习的社区检测方法 研究

Research on Community Detection Methods based on Local Information Structure Enhancement and Graph Contrastive Learning

指导教师姓名: ***

专 业 名 称: 控 制 工 程

论文提交日期: 2026 年 4 月

论文答辩日期: 年 月

学位授予日期: 年 月

年 月

厦门大学学位论文原创性声明

本人呈交的学位论文是本人在导师指导下，独立完成的研究成果。本人在论文写作中参考其他个人或集体已经发表的研究成果，均在文中以适当方式明确标明，并符合法律规范和《厦门大学研究生学术活动规范（试行）》。

另外，该学位论文为（ ）课题（组）的研究成果，获得（ ）课题（组）经费或实验室的资助，在（ ）实验室完成。（请在以上括号内填写课题或课题组负责人或实验室名称，未有此项声明内容的，可以不作特别声明。）

本人声明该学位论文不存在剽窃、抄袭等学术不端行为，并愿意承担因学术不端行为所带来的一切后果和法律责任。

声明人（签名）：

指导教师（签名）：

年 月 日

厦门大学学位论文著作权使用声明

本人同意厦门大学根据《中华人民共和国学位条例暂行实施办法》等规定保留和使用此学位论文，并向主管部门或其指定机构送交学位论文（包括纸质版和电子版），允许学位论文进入厦门大学图书馆及其数据库被查阅、借阅。本人同意厦门大学将学位论文加入全国博士、硕士学位论文共建单位数据库进行检索，将学位论文的标题和摘要汇编出版，采用影印、缩印或者其他方式合理复制学位论文。

本学位论文属于：

（ ） 1. 经厦门大学保密委员会审查核定的涉密学位论文，
于 年 月 日解密，解密后适用上述授权。

（ ） 2. 不涉密，适用上述授权。

（请在以上相应括号内打“√”或填上相应内容。涉密学位论文应是已经厦门大学保密委员会审定过的学位论文，未经厦门大学保密委员会审定的学位论文均为公开学位论文。此声明栏不填写的，默认为公开学位论文，均适用上述授权。）

声明人（签名）：

年 月 日

摘要

随着现实世界数字化与信息化的飞速发展，复杂网络的规模与交互关系呈现出指数级的增长趋势。在这些错综复杂的网络结构中，节点间密集的协同互动形成了各种功能性的社区。精准检测并划分这些社区，不仅有助于理解真实世界系统的底层组织规律与演化机制，更为挖掘节点潜在关系、支撑精准推荐以及信息传播分析等下游任务提供了重要基础。近年来，深度图表示学习凭借其强大的特征提取能力，为复杂网络社区检测领域提供了新的思路和方法。但在面对大规模的真实网络时，传统的全局社区检测难以保证高质量的社区划分，更为高效灵活的局部社区检测逐渐成为该领域的主流研究方向。然而，现有的局部社区检测方法在拓扑连通与高阶建模方面仍面临诸多问题。一方面，现有方法在整合网络的多维信息时，往往难以保持局部结构之间的连通性，容易破坏真实社区内的连接关系，导致社区被过度分割；另一方面，现有方法难以有效捕捉复杂的群体协同模式，若直接引入高阶结构又容易导致过度聚焦密集区域的核心偏置难题。为解决这些问题，本文开展了以下研究工作：

(1) 针对局部社区检测方法在生成初始种子时没有充分使用节点属性信息，且忽略了种子社区之间的内在连接关系，导致社区被过度分割的问题，本文提出了一种基于连通种子结构和图对比学习的社区检测方法（Community Detection Based on Connected Seed Structures and Graph Contrastive Learning, CSSGCL）。为更全面地刻画复杂网络的真实组织结构，CSSGCL 利用变分图自编码器融合低阶拓扑与属性特征生成增强图，并在此基础上提取极大 k -plex 结构构建孤立种子社区。随后，CSSGCL 依托原始拓扑连接关系构建出兼顾内部凝聚力与全局连通性的连通种子社区，保留了种子社区之间的连接关系，克服了将种子视为孤立社区的局限性。最后，通过双视图对比学习机制指导种子社区合并与扩展。实验结果表明，该方法有效克服了局部社区检测的过度分割问题，能够获得高质量的社区划分结果。

(2) 针对局部社区检测方法依赖低阶拓扑导致社区边界模糊，以及引入高阶结构容易引发核心偏置的难题。本文提出了一种基于基序感知和图对比学习的社区

检测方法 (Motif-aware Graph Contrastive Learning for Community Detection, MAC)。

该方法通过构建高阶基序超图与高低阶双通道架构,协同对齐基础邻接与深层语义特征,以充分挖掘群体协同模式。此外,为避免模型在扩展时向连接密集的网络核心区域偏移,本文设计了一种基于三角基序的社区质量评价函数,在扩展阶段优先筛选高质量种子,并以结构和特征一致性为约束指导种子社区有序向外扩展。在多个真实数据集上的实验表明,该方法能够对复杂网络社区进行高质量划分,并有效缓解了核心偏置现象。

(3) 针对基于深度图学习模型的社区检测方法缺乏可解释性的问题,本文引入图掩码机制与互信息理论,探索了基于局部信息的社区检测模型的可解释性分析方法。该方法一方面通过掩码保留机制提取网络核心骨架,验证了高阶基序在指导局部社区稳健成型中的决定性作用;另一方面通过对三角基序的破坏性扰动测试,验证了三角基序在把控种子社区扩展方向上的合理性。

关键词: 社区检测; 种子社区; 图对比学习; 基序

Abstract

With the rapid development of real-world digitalization and informatization, the scale and interactions of complex networks are growing exponentially. Within these intricate network structures, dense collaborative interactions among nodes form various functional communities. Accurately detecting and partitioning these communities not only helps in understanding the underlying organizational rules and evolutionary mechanisms of real-world systems, but also provides a crucial foundation for downstream tasks such as mining latent node relationships, supporting precise recommendations, and analyzing information diffusion. Recently, deep graph representation learning has provided new approaches for complex network community detection, owing to its powerful feature extraction capabilities. However, when facing large-scale real-world networks, traditional global community detection struggles to ensure high-quality community partitions. Thus, more efficient and flexible local community detection has gradually become the mainstream research direction in this field. Nevertheless, existing local community detection methods still face many challenges in topological connectivity and high-order modeling. On the one hand, when integrating multi-dimensional network information, existing methods often struggle to maintain connectivity between local structures. This easily breaks the connections within real communities, leading to over-segmentation. On the other hand, it is difficult for current methods to effectively capture complex group collaboration patterns. Directly introducing high-order structures often leads to a "core bias" problem, where the model overly focuses on densely connected regions. To address these issues, this thesis conducts the following research:

(1) Existing local community detection methods often fail to fully utilize node attribute information when generating initial seeds and ignore the intrinsic connections between seed communities, leading to over-segmentation. To address this, we propose a Community Detection method Based on Connected Seed Structures and Graph

Contrastive Learning (CSSGCL). To more comprehensively capture the real organizational structure of complex networks, CSSGCL uses a Variational Graph Autoencoder (VGAE) to fuse low-order topology and attribute features to generate an augmented graph. Based on this, it extracts maximal k -plex structures to construct isolated seed communities. Subsequently, relying on original topological links, CSSGCL constructs connected seed communities that balance internal cohesion and global connectivity. This preserves the connections between seed communities and overcomes the limitation of treating seeds as isolated units. Finally, a dual-view contrastive learning mechanism is used to guide the merging and expansion of seed communities. Experimental results show that this method effectively overcomes the over-segmentation problem in local community detection and achieves high-quality community partitions.

(2) Relying solely on low-order topology in local community detection blurs community boundaries, while introducing high-order structures easily triggers core bias. To solve these problems, we propose Motif-aware Graph Contrastive Learning for Community Detection (MAC). This method constructs a high-order motif hypergraph and a dual-channel architecture. It collaboratively aligns basic adjacency and deep semantic features to fully mine group collaboration patterns. Furthermore, to prevent the model from shifting towards densely connected core regions during expansion, we design a community quality evaluation function based on triangle motifs. This function prioritizes high-quality seeds during the expansion phase and guides the orderly outward expansion of seed communities under the constraints of structural and feature consistency. Experiments on multiple real-world datasets demonstrate that this method can achieve high-quality partitions for complex network communities and effectively mitigates the core bias phenomenon.

(3) Deep graph learning models for community detection often lack interpretability. To address this issue, this thesis introduces a graph masking mechanism and mutual information theory to explore interpretability analysis methods for local-information-based community detection models. On the one hand, this method extracts the core

network skeleton through a mask retention mechanism, verifying the decisive role of high-order motifs in guiding the robust formation of local communities. On the other hand, through destructive perturbation tests on triangle motifs, it validates the rationality of using triangle motifs to control the expansion direction of seed communities.

Keywords: Community Detection; Seed Community; Graph Contrastive Learning; Motif

摘要.....	I
Abstract.....	III
目 录.....	VII
Table of Contents	XI
第 1 章 绪论.....	1
1.1 研究背景和意义.....	1
1.2 国内外研究现状.....	2
1.2.1 基于全局信息的社区检测方法.....	3
1.2.2 基于局部信息的社区检测方法.....	4
1.3 本文主要研究内容.....	6
1.4 本文结构安排.....	7
第 2 章 预备知识和基础理论	9
2.1 社区检测.....	9
2.1.1 社区结构.....	9
2.1.2 社区检测方法常用的评价指标.....	11
2.2 图神经网络.....	12
2.2.1 图卷积神经网络.....	13
2.2.2 变分图自编码器.....	14
2.2.3 图对比学习.....	16
2.2.4 超图神经网络.....	18
2.3 基序结构.....	19
2.4 本章小结.....	21
第 3 章 基于连通种子结构和图对比学习的社区检测方法.....	23
3.1 引言.....	23
3.2 模型和方法.....	24
3.2.1 网络拓扑增强.....	24

3.2.2 种子社区的构建	26
3.2.3 种子社区的合并	27
3.2.4 种子社区的扩展	29
3.3 实验验证与结果分析	30
3.3.1 数据集与评价指标介绍	30
3.3.2 实验设置	33
3.3.3 对比方法	33
3.3.4 主要实验结果	35
3.3.5 消融实验	41
3.3.6 模型收敛性分析	42
3.3.7 超参数分析	43
3.4 本章小结	45
第 4 章 基于基序感知和图对比学习的社区检测方法	47
4.1 引言	47
4.2 模型和方法	48
4.2.1 基于基序的超图构建	49
4.2.2 高低阶双通道图对比学习	51
4.2.3 高低阶特征融合	54
4.2.4 种子社区质量评价与扩展指导	54
4.3 实验验证与结果分析	58
4.3.1 数据集与评价指标	58
4.3.2 实验设置	60
4.3.3 对比方法	61
4.3.4 主要实验结果	62
4.3.5 消融实验	65
4.3.6 超参数分析	66
4.3.7 社区划分可视化	68
4.3.8 复杂度分析	69
4.4 本章小结	70
第 5 章 基于掩码与互信息的社区检测模型可解释性分析	73
5.1 引言	73
5.2 基于掩码与互信息的社区检测模型可解释性分析	74
5.2.1 基于掩码保留机制的高阶基序贡献分析	74
5.2.2 基于掩码破坏机制的局部扩展结构依赖性分析	78

5.3 本章小结.....	79
第 6 章 总结与展望	81
6.1 总结.....	81
6.2 展望.....	82
参考文献.....	85
致 谢.....	91
在学期间完成的相关学术成果	92

Table of Contents

Abstract (In Chinese)	I
Abstract (In English)	III
Table of contents (In Chinese)	VII
Table of contents (In English)	XI
Chapter 1 Introduction	1
1.1 Research Background and Significance	1
1.2 Research Status at Home and Abroad	2
1.2.1 Community Detection Methods Based on Global Information	3
1.2.2 Community Detection Methods Based on Local Information	4
1.3 Main Research Content of This Thesis	6
1.4 Arrangement of This Thesis	7
Chapter 2 Preliminary Knowledge and Basic Theory	9
2.1 Community Detection	9
2.1.1 Community Structure	9
2.1.2 Common Evaluation Metrics for Community Detection	11
2.2 Graph Neural Networks	12
2.2.1 Graph Convolutional Networks	13
2.2.2 Variational Graph Autoencoders.....	14
2.2.3 Graph Contrastive Learning	16
2.2.4 Hypergraph Neural Networks	18
2.3 Motif Structures	19
2.4 Summary of This Chapter	21
Chapter 3 Community Detection Based on Connected Seed Structures and Graph Contrastive Learning	23
3.1 Introduction	23
3.2 Model and Methodology	24
3.2.1 Network Topology Augmentation	24
3.2.2 Construction of Seed Communities.....	26
3.2.3 Merging of Seed Communities	27
3.2.4 Expansion of Seed Communities	29
3.3 Experimental Validation and Results Analysis	30

3.3.1 Introduction to Datasets and Evaluation Metrics	30
3.3.2 Experimental Settings	33
3.3.3 Baseline Methods	33
3.3.4 Main Experimental Results	35
3.3.5 Ablation Study.....	41
3.3.6 Convergence Analysis.....	42
3.3.7 Hyperparameter Analysis	43
3.4 Summary of This Chapter	45
Chapter 4 Motif-aware Graph Contrastive Learning for Community Detection	47
4.1 Introduction	47
4.2 Model and Methodology	48
4.2.1 Motif-based Hypergraph Construction.....	49
4.2.2 High- and Low-Order Dual-Channel Graph Contrastive Learning	51
4.2.3 High- and Low-Order Feature Fusion	54
4.2.4 Seed Community Quality Evaluation and Expansion Guidance.....	54
4.3 Experimental Validation and Results Analysis	58
4.3.1 Introduction to Datasets and Evaluation Metrics	58
4.3.2 Experimental Settings	60
4.3.3 Baseline Methods	61
4.3.4 Main Experimental Results	62
4.3.5 Ablation Study.....	65
4.3.6 Hyperparameter Analysis	66
4.3.7 Visualization of Community Partition	68
4.3.8 Complexity Analysis	69
4.4 Summary of This Chapter	70
Chapter 5 Interpretability Analysis of Community Detection Model Based on Masking and Mutual Information	73
5.1 Introduction	73
5.2 Interpretability Analysis of Community Detection Model Based on Masking and Mutual Information	74
5.2.1 Contribution Analysis of High-Order Motifs Based on Mask Retention Mechanism	74
5.2.2 Structural Dependency Analysis of Local Expansion Based on Mask Disruption Mechanism	78
5.3 Summary of This Chapter	79

Chapter 6 Conclusion and Future Work.....	81
6.1 Summary of This Work	81
6.2 Future Work	82
References	85
Acknowledgements	91
Relevant Academic Achievements Completed During the Academic Period	92

第1章 绪论

1.1 研究背景和意义

复杂网络广泛存在于现实世界的各个领域，如电力能源网、城市交通网及社交网络等^[1]。复杂网络理论凭借其强大的拓扑表征能力，已成为揭示现实世界系统内在组织机制的核心工具^[2]。研究发现，复杂网络的节点并非均匀分布，而是呈现出聚类聚集特征，即倾向于形成内部连接稠密、外部连接稀疏的子结构。这种普遍存在的拓扑性质被称为社区结构^[3]。社区检测的核心目标便是识别出这类社区结构，进而揭示网络内在特征、理解网络动态行为以及优化信息流通效率。这种“结构反映功能”的特性具有重要的实际应用价值：例如，在工业物联网中，通过识别传感器社区可实现故障快速溯源^[5]；在城市交通网络中，合理的社区划分有助于精准定位拥堵瓶颈，为路网规划提供科学指导^[6]；在社交网络中，挖掘具有共同兴趣或行为模式的用户社区，则能有效支撑个性化推荐系统的构建与精准营销策略的制定^[7]。

作为分析复杂网络结构与行为机制的关键手段，社区检测技术能够有效挖掘出网络内部的潜在模式，进而为科学决策与系统优化提供有力的数据支撑。在该领域的发展过程中，早期学者提出了许多经典算法，例如基于模块度优化的 Louvain 算法^[8]、基于信息论的标签传播算法（Label Propagation Algorithm, LPA）^[9]以及谱聚类算法^[10]等。然而，面对当今大规模且高度复杂的网络系统，这些依赖全局拓扑信息的经典方法面临检测精度与网络规模难以兼顾的瓶颈。具体而言，上述基于全局信息的社区检测方法往往在小规模网络中表现优异，但在大型网络中，却难以提取出具有实际意义的社区结构。此外，这类方法从全局宏观视角进行社区划分时，往往会面临分辨率限制问题^[11]，导致大型网络中高度内聚但体量较小的精细社区被错误合并或覆盖，降低了社区划分结果的可靠性。而从微观维度切入的基于局部信息的社区检测方法，为突破这一瓶颈提供了有效路径^[12]。该类方法摒弃了对全局拓扑的依赖，转而聚焦于节点的局部邻接状态，通过准确定位网络中的核心种子节点并向外扩展，能够不受整体网络规模的干扰，精准地检测出目标社区，从而规避了全

局划分时小社区被错误合并的风险^[13]。

以往的局部社区检测方法，大多依靠简单的拓扑规则进行种子提取与扩展^[14]。然而，随着现实网络规模的急剧扩大以及对网络复杂关系挖掘需求的不断提升，当前研究的关注点逐渐转向了如何更精准、全面地捕捉网络的深层结构信息^[15]。在此背景下，基于局部种子扩展的传统方法在实际应用中暴露出两大问题：首先，在种子生成阶段，现有方法过度依赖单纯的拓扑连接关系，未充分使用节点自身的高维属性，且忽略了种子之间客观存在的连通关系，将生成的种子视为相互孤立的“孤岛”。这种将种子孤立对待的处理方式，破坏了真实网络的内在连通语义，导致原本结构完整的社区被过度分割。其次，在种子扩展阶段，现有方法面临着种子社区质量评估缺失与拓扑利用不充分的局限：一方面受限于低阶拓扑的表达局限，难以刻画多节点间的复杂协同模式；另一方面在引入高阶基序结构时，因过度依赖其出现频率而陷入“核心偏置”，导致种子社区扩展容易向网络中连接密集的中心区域偏移。这种机制层面的偏差，使得方法难以精准划分社区的真实边界，进而降低了社区划分结果的鲁棒性。

随着人工智能与深度学习技术的快速发展，基于图神经网络（Graph Neural Network, GNN）和图对比学习（Graph Contrastive Learning, GCL）的社区检测模型逐渐兴起^[16]，并在图数据的表示学习方面展现出了独特的优势。这类模型能够通过图的拓扑传播过程，编码隐藏在多跳链接中的复杂关系与节点的高维属性特征，为解决局部种子生成的孤立性问题以及扩展过程的高阶信息缺失问题提供了新的解决途径^[17]。因此，本文引入图对比学习与高阶基序感知等技术，探索保持网络真实连通语义的局部表征机制以及挖掘复杂群体交互模式的扩展策略，旨在克服现有局部社区检测算法在孤岛假设与引入高阶基序结构导致的核心偏置的局限性。

1.2 国内外研究现状

社区检测是复杂网络分析中的一项关键任务，旨在将网络节点划分为内部连接紧密、外部连接稀疏的子结构。本章将分别从基于全局信息的社区检测方法和基于局部信息的社区检测方法两个维度，系统梳理国内外相关研究进展。

1.2.1 基于全局信息的社区检测方法

传统的全局社区检测方法主要依赖于完整的初始网络拓扑结构来进行社区挖掘。此类方法的核心思想是：网络中连接紧密的节点，更倾向于形成内聚性强、功能关联的群体^[18]。早期的研究大多围绕图的整体宏观特征如边密度、全局连通性等展开^[19]，主要包括基于图分割的方法、基于层次聚类的方法、基于模块度优化的方法以及基于信息论的方法等。

基于图分割的方法：该方法旨在将网络划分为预定数量的子图，同时使子图之间的连接边数即割集最小化。Kernighan 等人^[20]提出了经典的 Kernighan-Lin (KL) 算法，该算法首先将网络随机划分为两个规模相等的子集，随后通过计算节点交换带来的增益，不断迭代交换两个子集中的节点，最终实现割边数量的局部最优。Shi 等人^[21]提出了基于谱图理论的归一化割算法，该算法将传统的图最小割问题转化为求解网络拉普拉斯矩阵的广义特征值问题，借助全局特征向量信息，避免了传统最小割算法易切分出孤立节点的缺陷，从全局数学视角的层面上实现了更加平滑的网络分割。

基于层次聚类的方法：该方法致力于自底向上或自顶向下地揭示网络的层次化社区结构。Girvan 和 Newman^[3]提出的 GN 算法是该方法的代表性算法。该算法基于“边介数”的核心概念即网络中所有最短路径经过某条边的次数，通过不断识别并移除网络中介数最高的边，自顶向下逐步拆分网络，最终得到底层的社区结构。Ng 等人^[10]提出了谱聚类算法，该算法通过全局网络的邻接关系构建相似度矩阵与标准化的拉普拉斯矩阵，提取拉普拉斯矩阵的前 k 个主特征向量以构建低维嵌入空间，并最终在低维空间内应用 K-means 算法完成节点聚类。然而，大多数谱聚类算法需要预先人工指定社区的数量 k ，这在缺乏全局先验知识的真实复杂网络中往往难以实现，并且会影响检测精度。

基于模块度优化的方法：该方法建立在 Newman 等人提出的模块度 (Modularity) 指标的基础上。Louvain 算法^[8]是这类方法的典型代表，它通过不断将节点并入能带来最大全局模块度增益的相邻社区，并在每次迭代后将社区折叠为超级节点，实现了社区的快速划分，兼顾了检测速度与精度。Traag 等人^[22]进一步提出了 Leiden 算

法。该算法在局部移动和社区聚合之间引入了细化机制，有效弥补了 Louvain 算法可能导致社区内部结构断裂的不足，保证了划分后社区内部的强连通性。

基于信息论的方法：该方法从信息传播和数据压缩的独特视角来理解社区结构。Rosvall 等人^[23]提出的 Infomap 算法，通过模拟网络中的全局随机游走，并结合哈夫曼编码思想，寻找能够最小化游走路径平均描述长度的编码方案，进而精准揭示网络的模块化特征。Raghavan 等人^[9]提出的标签传播算法 (Label Propagation Algorithm, LPA) 利用节点标签的迭代更新来模拟局部信息的扩散过程，以极低的时间复杂度实现了高效的社区划分，适用于大规模网络的快速检测。

尽管上述基于全局信息的经典方法在理论体系与实际应用中均取得了很好的成果，但在面对大型复杂网络时，逐渐暴露出难以克服的瓶颈。以 Louvain 为代表的模块度优化方法存在理论上已被证明的分辨率限制缺陷^[24]，即在大型复杂网络中，算法倾向于将本应独立的小型高内聚结构错误合并。基于全局信息的算法普遍存在难以在检测精度与网络规模之间实现平衡的问题，促使研究者们将重心逐渐转移至更为灵活高效的基于局部信息的社区检测方法上。

1.2.2 基于局部信息的社区检测方法

为克服全局社区检测算法在大型网络中存在的划分质量不佳、分辨率受限等问题，基于局部信息的社区检测算法应运而生。其核心思想是“以点带面”，无需预先掌握完整的网络拓扑结构，而是从少量已知的核心种子节点或局部子图出发，依托局部邻域信息向外围进行启发式扩展^[25]。按照核心驱动机制的不同，主流的局部社区检测方法主要可分为以下三类：

基于启发式规则与局部拓扑度量的方法：这类方法主要以网络的局部拓扑特征如局部连通密度、度分布变化等作为核心评估标准，通过最大化局部结构指标来识别核心种子并扩展社区。例如，Clauset 等人^[26]提出了一种基于局部模块度的贪心扩展算法，通过计算并最大化局部边界节点的模块度增量来逐步扩展邻居节点，奠定了局部社区扩展的理论框架。在种子节点的选择方面，Liu 等人^[27]提出了一种融合节点 k -shell 值与局部聚类系数的影响力评估算法。该算法先通过设定阈值筛选出高质量的初始种子集，再基于节点自重、距离权重及共同邻居等因素计算连接强度，

将非种子节点唯一地分配至连接最强的种子社区中，实现了高效的非重叠社区划分。此外，Zhu 等人^[28]则从密集子图的视角出发，将具有极高内聚性的 k -plex 结构识别为初始种子社区，再通过模块度优化完成最终的局部社区扩展。尽管这类启发式方法规则设计明确且具有较高的计算效率，但大多仅依赖网络中的低阶成对连接，且结构特征提取高度依赖人工定义，难以有效捕捉复杂网络中深层、非线性的拓扑划分模式。

基于随机游走与信息传播的方法：其核心原理是利用游走节点在社区内部停留时间长、跨越边界概率低的特性，通过模拟信息扩散来定位划分边界。例如 Spielman 等人^[29]提出了基于局部 PageRank 向量的近似算法，通过截断随机游走来快速定位局部划分边界，使其时间复杂度仅与目标社区规模相关，大幅提升了算法效率。Das 等人^[30]提出了 PraSar 的算法，通过分析局部网络中信息交换的级联模式提取核心种子，并以最小化外部连接为目标，将外围节点精准合并至唯一的种子社区中。Wang 等人^[31]则构建了基于信息传递概率的中心性度量，在识别出最具影响力的节点作为社区中心后，利用 K 个中心点聚类精准检测出非重叠的局部社区。此类算法虽然在理论上证明了局部扩展的有效性，但在面对现实世界中普遍存在的属性网络时，仅依赖图拓扑的转移概率往往难以捕捉节点间丰富的语义关联。

基于图深度学习与高阶特征表示的方法：为解决属性网络中高维特征与复杂拓扑难以融合的难题，图神经网络 (Graph Neural Network, GNN) 与图对比学习 (Graph Contrastive Learning, GCL) 逐渐成为局部社区检测的重要工具。图嵌入技术通过随机游走结合 Skip-Gram 模型^[32]，将节点映射为低维稠密向量，实现拓扑结构的初步表征。而 GNN 则通过在图拓扑上进行消息传递，实现了节点拓扑结构与属性特征的有效融合^[33]。Jin 等人^[34]提出的 MRFaSGCN 模型将马尔可夫随机场引入图卷积层，提升了局部社区边界预测的平滑性；Chen 等人^[35]提出的 KPGN 框架在生成 k -plex 种子社区后，利用 GraphSAGE 模型的邻居采样与聚合机制学习节点特征，进而为外围节点精确分配唯一的非重叠社区标签。与此同时，研究者意识到多节点协同交互所形成的高阶结构特别是网络基序 (Motif) 比低阶的单条边更能准确刻画非重叠社区的边界。在高阶特征学习方面，Edmot^[36]利用高阶基序的聚类结果向原始网络添加增强边，指导深层模型更好地捕提高阶拓扑语义；MotifCC^[37]则通过图对

比学习框架，将高阶的三角基序语义与低阶拓扑特征有效映射到统一的潜空间中，提升了特征表示的判别能力；此外，基于基序嵌入的标签传播算法通过联合高阶基序对原始网络进行结构重构，大幅增强了深层模型对局部高内聚区域的拓扑感知能力。为了更完备地表达多节点间的复杂协同关联，超图神经网络（Hypergraph Neural Networks, HGNN）被进一步引入。Feng 等人^[38]率先将超图结构学习引入图神经网络，提出了两阶段超图卷积框架，有效克服了低阶连接的表达局限；Bai 等人^[39]随后引入了超图卷积和超图注意力机制作为端到端的可训练算子，提升了高阶特征的提取效率与精准度。针对复杂超图中信息传递效率偏低的问题，Kang 等人^[40]提出基于关键超边的动态 HGNN 模型，进一步优化了高阶信息的传播效率。这些高阶图学习方法的引入，极大地提升了模型对复杂拓扑的表达与局部社区划分能力。

然而，在将图学习与高阶结构应用于局部社区检测任务时，种子社区的提取与扩展是核心关键环节。无论是利用基序增强网络结构，还是利用超图进行高阶节点表示，最终都需落脚于种子社区的生成与合理扩展。现有模型往往将生成的种子视为孤立实体，忽视了种子之间客观存在的连通关联，易引发语义相关社区的过度分割。此外，目前将高阶结构应用于局部社区检测的探索中，缺乏对种子社区结构质量的量化与评估机制，算法在扩展过程中对内部紧密度不同的种子采取统一的扩展标准，导致社区偏向连接密集的中心区域扩展，无法实施差异化的指导策略，限制了局部划分的鲁棒性和社区划分的准确性。

1.3 本文主要研究内容

社区检测作为解析交通、电力与社交等复杂网络中社区结构的重要手段，近年来在深度学习技术的发展下取得了显著进展。目前的社区检测研究已从单一利用图拓扑或节点信息，转向深度融合多维特征、追求更高结构一致性的方向，通过图神经网络挖掘非线性的特征已成为主流趋势。然而，现有的局部种子扩展方法在生成种子时往往割裂了种子社区间的客观连通性且未充分使用节点属性，同时在扩展阶段也缺乏对高阶结构如网络基序的协同利用以及对种子质量差异的评估。针对上述不足，本文在分析现有深度图学习技术的基础上，致力于从节点属性融合、全局信

息对齐以及高阶协同交互等多个维度，提升社区检测的准确性与鲁棒性。本文的主要工作总结如下：

(1) 提出了一种基于连通种子结构和图对比学习的局部社区检测方法 CSSGCL。针对现有方法生成种子社区时未充分使用节点属性的问题，该方法利用变分图自编码器将节点的高维属性映射到重构的拓扑空间中，进而捕捉节点真实的结构与属性关联；同时，针对现有方法孤立化种子社区导致的过度分割问题，该方法保留了 k -plex 种子间的边连接，构建形成连通图。通过设计图对比学习模块，在统一的潜空间中对齐孤立与连通种子的特征表示，实现了局部强内聚性与全局连通信息的平衡。

(2) 提出了一种基于基序感知和图对比学习的社区检测方法 MAC。该方法突破了传统低阶成对连接的局限，利用三阶与四阶基序显式构建高阶结构超图，并通过剔除嵌套结构减少信息冗余，从而精准刻画多节点间的协同交互关系。为实现多层次拓扑语义的对齐，模型采用图卷积与超图卷积的双通道编码架构，在统一表示空间中实现低阶邻接特征与高阶结构特征的对齐。在最终的扩展阶段，本文通过将传统模块度推广至高阶层面，提出了一种基于三角形基序的社区质量评价函数以量化种子的内部凝聚力，并结合结构约束与特征表示一致性，指导社区实现稳健扩展。有效缓解了引入高阶结构易偏向网络核心区域的难题，实现了社区划分在完整度与准确性上的提升。

(3) 探索了基于图掩码机制与互信息理论的局部社区检测模型可解释性分析方法。针对现有深度图学习社区检测模型可解释性的难题，本文设计了图掩码测试机制。一方面，通过设计掩码保留机制提取网络中的高阶拓扑骨架，验证了高阶基序在锚定局部社区高内聚核心中的决定性作用；另一方面，通过对核心三角基序施加破坏性扰动测试，验证了三角基序结构在指导社区稳健扩展上的合理性。

1.4 本文结构安排

本文的各个章节内容按照以下顺序进行安排：

第一章：绪论。主要说明了选题的研究背景及意义、社区检测方法的国内外研

究现状以及复杂网络高阶结构的发展情况，同时概括了本文的主要研究内容与整体组织结构。

第二章：预备知识和基础理论。对本文研究中所涉及的基础理论进行系统介绍，具体包括社区检测的相关定义、图神经网络的相关概念以及网络基序的定义。

第三章：提出基于连通种子结构和图对比学习的局部社区检测方法 CSSGCL。首先，对 CSSGCL 的实现细节进行了介绍，包括基于变分图自编码器的网络重构、连通种子社区的构建、种子社区的合并以及基于标签传播的种子社区扩展等。其次，明确实验中使用的数据集、对比基线算法和评价指标。最后，通过不同数据集上的对比实验、消融实验以及超参数敏感性分析，验证了该算法在提升网络划分准确性和避免社区过度分割方面的有效性。

第四章：提出基于基序感知和图对比学习的社区检测方法 MAC。首先介绍了 MAC 模型的主要结构，包括利用三阶和四阶基序构建高阶结构超图并进行去嵌套处理、图卷积与超图卷积双通道的对比学习。其次，详细阐述了提出的基于三角基序的种子社区质量评价函数，以及联合高阶结构与特征表示一致性的指导扩展策略。最后，通过一系列的对比实验分析了 MAC 在基于局部信息的社区检测问题上的性能表现，验证了高低阶拓扑语义联合建模的优越性。

第五章：提出基于掩码与互信息理论的局部社区检测模型可解释性分析方法。首先，设计高阶掩码矩阵并最大化互信息，实现高阶拓扑重要性分析。其次，引入基于最小化互信息的扰动分析，分析基于三角基序结构构建种子扩展指导函数的重要性。最后，通过可视化与量化讨论，验证了高阶基序与高质量种子在社区成型过程中的重要作用，验证了本文方法的合理性。

第六章：总结与展望。对全文的研究工作进行了系统性地总结，并对未来在复杂网络社区检测领域的进一步研究进行了展望。

第2章 预备知识和基础理论

2.1 社区检测

社区检测 (Community Detection) 是网络科学中研究最早、最为核心的问题之一, 其核心目标是揭示复杂网络的结构特性和节点组成规律。在探讨具体的局部种子扩展方法与高低阶拓扑结构之前, 我们先对图的数据结构及社区的相关概念进行介绍。

2.1.1 社区结构

现实世界中的各类复杂关系通常被抽象为图结构数据。不失一般性, 本文的研究主要聚焦于无向图。给定一个无向图 $G=(V, E)$, 其中 $V=\{v_1, v_2, \dots, v_N\}$ 表示图中的节点集合, $E=\{e_1, e_2, \dots, e_p\}$ 表示边的集合。这里的 N 和 p 分别代表网络中节点的总数量和边的总数量。在复杂网络中, 每个节点代表一个独立的实体, 而边 $e_k=(v_i, v_j)$ 则表示节点 v_i 与节点 v_j 之间存在的交互或连接关系。

为了在计算机及神经网络中有效地表示和处理图数据, 通常使用邻接矩阵来刻画其内在的拓扑关系。图 G 的邻接矩阵表示为 $A \in \{0,1\}^{N \times N}$ 。矩阵 A 中的元素 a_{ij} 指示了节点间的连通关系; 若节点 v_i 与节点 v_j 之间存在一条边, 则 $a_{ij}=1$; 否则 $a_{ij}=0$ 。同时, 节点的度定义为与该节点直接相连的边的数量。由此可定义网络的度矩阵 D 。度矩阵 D 是一个对角矩阵, 其对角线上的元素 D_{ii} 即为节点 v_i 的度, 而非对角线上的元素均为 0。除单纯的拓扑连接结构外, 现实世界复杂网络中的每个节点通常还关联着丰富的语义特征信息。因此, 可以为每个节点定义一个属性向量, 所有的节点属性向量共同构成了网络的节点属性矩阵 X 。在图深度学习中, 邻接矩阵 A 往往与属性矩阵 X 结合使用, 以便同时捕获网络的结构特性与节点自身的属性关联。

现实世界中的各类复杂网络, 并非由同一类相似节点随机连接构成, 而是由多

类不同性质的节点组合形成。这些网络中边的分布通常存在不均匀性：具有相似性质或关联密切的节点之间连接紧密，而不同性质的节点之间连接相对稀疏。这种由同类型或关系紧密的节点构成、内部连接密集而外部连接稀疏的局部连通子图，即为社区。图 2.1 展示了一个包含社区结构的典型网络，本文主要考虑非重叠社区形式。




图 2.1 典型社区网络

给定一个无向图 $G = (V, E)$ ，其邻接矩阵为 A 。假设 C 是节点集 V 的一个子集即 $C \subset V$ 。为定量刻画该子集内部的紧密程度，对于子集 C 中的任意节点 $v_i \in C$ ，我们可以将其总度数 k_i 划分为内部度和外部度两个部分。内部度 k_i^{in} 表示节点 v_i 与子集 C 内部其他节点相连的边数，其数学计算公式为：

$$k_i^{in} = \sum_{v_j \in C} A_{ij} \quad (2.1)$$

外部度 k_i^{out} 表示节点 v_i 与子集 C 外部节点相连的边数，其数学计算公式为：

$$k_i^{out} = \sum_{v_j \notin C} A_{ij} \quad (2.2)$$

节点 v_i 的总度数满足 $k_i = k_i^{in} + k_i^{out}$ 。

一个子集 C 若要被认定为一个社区，其内部节点之间的连接程度必须显著高于其与网络其余部分的连接程度，且最大化各子集的内部度与外部度之差。基于连通

性与紧密程度的图论定义,社区检测的本质就是将整个网络的节点集合 V 划分为 K 个互不重叠的子集 $\mathcal{C} = \{C_1, C_2, \dots, C_K\}$, 并满足以下划分条件:

$$V = C_1 \cup C_2 \cup \dots \cup C_K \quad (2.3)$$

$$C_i \cap C_j = \emptyset \quad (i \neq j) \quad (2.4)$$

其中, 每个子集 C_i 代表一个独立的社区。在理想的社区划分状态下, 对于任意社区 C_i , 其内部节点之间的边密度应显著高于该社区内节点与社区外节点之间的边密度。

2.1.2 社区检测方法常用的评价指标

在社区检测方法的性能评估中, 选择客观、定量的评价指标对于衡量社区划分质量至关重要。为了全面衡量社区结构的内部紧密程度, 以及预测结果与真实情况的吻合程度, 本文主要采用模块度 (Modularity)、标准化互信息 (Normalized Mutual Information, NMI) 以及相似度作为评估标准。

模块度是衡量社区结构质量最经典、应用最广泛的评估指标之一^[41]。其核心思想在于: 一个合理的社区划分, 应使社区内部的连接边数显著多于保持节点度分布不变的随机网络中的期望连接边数。模块度的值越高, 说明该划分方案下社区内部的凝聚力越强, 整体划分质量越优。对于一个无向图, 模块度 Q 的数学定义如下:

$$Q = \frac{1}{2m} \sum_{i,j} \left(A_{ij} - \frac{k_i k_j}{2m} \right) \delta(s_i, s_j) \quad (2.5)$$

其中, m 表示网络中边的总数量, A_{ij} 为邻接矩阵的元素, 若节点 i 与节点 j 之间存在连边则为 1, 否则为 0; k_i 和 k_j 分别表示节点 i 和节点 j 的度; s_i 和 s_j 分别代表节点 i 和节点 j 所属的社区标签; $\delta(s_i, s_j)$ 为指示函数, 当且仅当节点 i 与节点 j 属于同一个社区时 $\delta(s_i, s_j) = 1$, 否则为 0。公式中第一项 A_{ij} 代表真实的网络连通情况, 第二项 $\frac{k_i k_j}{2m}$ 则代表随机网络中的期望边数, 两者的差值可量化社区内部的凝聚力强弱。

标准化互信息 (Normalized Mutual Information, NMI)^[42]基于信息论, 用于衡

量算法得出的社区划分与标准的社区划分之间的相似度。NMI 的取值范围在 0 到 1 之间，值越高表示社区划分结果与标准划分的匹配度越好。其定义如下：

$$NMI = \frac{2 \times I(C^*, C)}{H(C^*) + H(C)} \quad (2.6)$$

其中， C^* 表示网络中标准的社区划分， C 表示由算法检测得到的社区划分结果。 $I(C^*, C)$ 表示划分 C^* 与 C 之间的互信息，用于量化两者之间共享的信息量； $H(C^*)$ 和 $H(C)$ 分别代表标准划分和预测划分的信息熵。归一化操作避免了互信息偏向于社区数量更多的划分结果，保障了评估的公平性。

F-Score 相似度^[43]结合了精确率与召回率的思想，用于综合衡量标准社区与检测到的社区之间的重叠相似程度。其数学表达式定义如下：

$$S(C^*, C) = \frac{1}{2|C^*|} \sum_{C_i^* \in C^*} \max_{C_j \in C} \delta(C_i^*, C_j) + \frac{1}{2|C|} \sum_{C_j \in C} \max_{C_i^* \in C^*} \delta(C_i^*, C_j) \quad (2.7)$$

其中， C^* 为标准社区集合， C 为检测到的社区集合， $|C^*|$ 和 $|C|$ 分别表示对应集合中包含的社区数量。 $\delta(C_i^*, C_j)$ 表示标准社区 C_i^* 与检测社区 C_j 之间的相似度度量函数，通常采用 F-score 或 Jaccard 相似系数。F-score 为 $F(C_i^*, C_j) = \frac{2|C_i^* \cap C_j|}{|C_i^*| + |C_j|}$ ，Jaccard 相似系数为 $J(C_i^*, C_j) = \frac{|C_i^* \cap C_j|}{|C_i^* \cup C_j|}$ ，相比于 Jaccard 系数，F-score 对集合大小的差异更为敏感，在评估大小分布极不平衡的社区结构时，能够提供更为平滑的相似度刻画。 $S(C^*, C)$ 指标通过双向匹配机制为每个标准社区寻找最相似的检测社区，同时为每个检测社区寻找最相似的标准社区，最终计算两者的平均相似度得分。该综合指标的取值同样介于 0 和 1 之间，得分为 1 意味着算法完美地恢复了标准的社区划分。

2.2 图神经网络

在现实世界的复杂网络中，除了拓扑连接外，节点通常还携带着丰富的高维属性信息。传统的深度学习方法虽然在图像和自然语言处理等领域取得了巨大的成功，但受限于对欧几里得空间数据的假设，难以直接适配错综复杂的图结构数据。相比

之下，图神经网络（Graph Neural Networks, GNN）作为一类专门设计来处理图结构数据的深度学习模型，凭借其强大的非线性特征提取能力，能够将图的拓扑结构与节点属性共同映射到统一的表示空间中^[44]。接下来将对本文所涉及的图神经网络相关技术进行介绍。

2.2.1 图卷积神经网络

图卷积神经网络（Graph Convolutional Network, GCN）^[45]是目前图表示学习领域应用最广泛、最具代表性的模型之一。传统的卷积神经网络在处理图像等规则的欧几里得空间数据时表现出了极大的优势，但无法直接适配节点度数不一、排列无序的非欧几里得图数据。图卷积神经网络的提出，将卷积操作从网格数据推广到了图结构数据，有效解决了这一难题。

图卷积神经网络的核心思想是基于局部邻域的消息传递，也称为邻居聚合机制。在图卷积的每一层中，节点会收集并聚合其一阶邻居节点的特征表示，并与自身特征进行融合后完成非线性变换，来更新每个节点的状态。经过多层网络堆叠，图卷积神经网络能够捕获网络中更大范围的拓扑依赖关系，实现节点特征的深度挖掘。

给定一个无向图 $G = (V, E)$ ，其邻接矩阵为 A ，节点特征矩阵为 $X \in \mathbb{R}^{N \times F}$ ，其中 N 为节点数， F 为初始特征维度。为了在聚合邻居特征时保留节点自身的特征，首先向图中节点添加自环，即令 $\hat{A} = A + I$ ， I 为单位矩阵。对应的对角线度矩阵记为 $\hat{D}$ ，其中 $\hat{D}_{ii} = \sum_j \hat{A}_{ij}$ 。GCN 的逐层传播公式定义如下：

$$X^{(l+1)} = \sigma \left(\hat{D}^{-\frac{1}{2}} \hat{A} \hat{D}^{-\frac{1}{2}} X^{(l)} \Theta^{(l)} \right) \quad (2.8)$$

其中， $X^{(l)}$ 表示第 l 层的节点隐藏特征矩阵，且初始输入特征为 $X^{(0)} = X$ ； $\Theta^{(l)}$ 为第 l 层可训练的参数权重矩阵； $\sigma(\cdot)$ 表示非线性激活函数，在图神经网络中通常采用 ReLU 函数以缓解过拟合。公式中的 $\hat{D}^{-\frac{1}{2}} \hat{A} \hat{D}^{-\frac{1}{2}}$ 是对添加了自环的邻接矩阵进行了对称归一化处理，目的是避免特征聚合过程中高度数节点的特征值被过度放大，低度数节点的特征值被削弱，从而保证特征在图拓扑上传播的数值稳定性。图 2.2 给出

了一个图卷积神经网络的计算示例。




图 2.2 图卷积神经网络计算示例

2.2.2 变分图自编码器

自编码器作为一种无监督学习模型，以重构输入数据为优化目标，将高维输入降维编码为低维隐变量。将该思想与图卷积神经网络相结合，便衍生出了图自编码器（Graph Auto-Encoder, GAE）。GAE 能够有效学习输入图数据的映射关系，生成节点的隐变量表示^[46]，为链路预测等下游任务提供支撑。在此基础上，为了赋予模型更强的生成能力，变分图自编码器（Variational Graph Auto-Encoder, VGAE）被进一步引入^[47]。VGAE 巧妙地结合了 GCN 的特征提取能力与变分推断的概率生成思想，不仅能学习图中节点在潜在空间中的近似分布，还可通过重构网络中的连接关系来实现对原始图数据的拓扑增强。VGAE 的典型结构如图 2.3 所示。其核心由推断模型编码器（Encoder）和生成模型解码器（Decoder）两部分组成。




图 2.3 变分图自编码器模型

编码器的主要作用是将原始图的拓扑结构和节点属性信息映射到低维的潜在表示空间，并拟合其潜在变量 Z 的均值和方差分布。通常采用两层共享部分权重的 GCN 作为编码器。第一层共享权重 GCN 用于提取共有的图特征表示，随后分支为两个并行的第二层 GCN 模型，第二层的卷积层的参数互相区别，分别用于推断潜在分布的均值矩阵 μ 和对数方差矩阵 $\log \sigma$ ：

$$\mu = \text{GCN}_{\mu}(X, A) \quad (2.9)$$

$$\log \sigma = \text{GCN}_{\sigma}(X, A) \quad (2.10)$$

基于推断出的 μ 和 σ ，潜在变量 Z 的后验分布 $q(Z | X, A)$ 可以被假设为一系列独立的高斯分布的乘积：

$$q(Z | X, A) = \prod_{i=1}^N q(z_i | X, A) = \prod_{i=1}^N \mathcal{N}(z_i | \mu_i, \text{diag}(\sigma_i^2)) \quad (2.11)$$

为了使模型在训练过程中能够通过反向传播算法更新梯度，VGAE 引入了重参数化技巧。由于直接从分布 $\mathcal{N}(\mu, \sigma^2)$ 中采样是一个不可导的操作，模型首先从标准正态分布 $\mathcal{N}(0, 1)$ 中采样一个辅助噪声向量 ϵ ，再通过线性变换得到潜在表示 $Z = \mu + \sigma \odot \epsilon$ ，其中， $\odot$ 表示哈达玛乘积。这一技巧将随机性转移到了无需计算梯度的 ϵ 上，保证了整个网络的可导性。

解码器的任务是利用采样得到的潜在表示 Z 来重构原始图的拓扑结构，即预测任意两个节点之间存在边连接的概率。VGAE 采用内积解码器来实现这一目标，对于潜在空间中的节点表示，其重构的边连接概率矩阵 $\hat{A} = \text{sigmoid}(ZZ^T)$ ，矩阵 $\hat{A}$ 中的元素 $\hat{A}_{ij}$ 反映了节点 v_i 与节点 v_j 之间的结构与属性相似性综合得分。

VGAE 的优化目标是最大化变分下界，其训练过程中的损失函数由两部分组成：第一部分是重构误差，通常采用交叉熵损失，用于确保生成的网络尽可能还原原始数据分布；第二部分是 Kullback-Leibler (KL) 散度，用于正则化潜在空间，使推断出的后验分布 $q(Z | X, A)$ 逼近标准正态分布 $p(Z)$ 。即：

$$\mathcal{L}_{VGAE} = L_{CE} - \text{KL}[q(Z | X, A) \| \prod_{i=1}^N \mathcal{N}(0, I)] \quad (2.12)$$

通过上述重构过程，模型能够根据节点间特征表示的相似度，添加高相关性边或移除低相关性边，最终生成兼具拓扑合理性与属性语义一致性的增强网络。

2.2.3 图对比学习

在图表示学习中，传统的图神经网络依赖于大量的节点标签进行监督训练。然而，在现实世界的复杂网络中，获取大规模真实社区标签往往需要耗费巨大的人力与时间成本，严重限制了监督式图学习模型的应用范围。为缓解对标注数据的依赖，图对比学习（Graph Contrastive Learning, GCL）作为一种自监督学习范式被引入到网络分析领域。Veličković 等人^[48]率先提出了 Deep Graph Infomax (DGI)模型，通过最大化局部节点表示与全局图结构之间的互信息，为图数据的自监督特征学习奠定了理论基础。随后，You 等人^[49]提出了经典的 GraphCL 框架，系统性地探讨并设计了多种图数据增强策略，极大地推动了图对比学习的发展。此外，Zhu 等人^[50]进一步引入了自适应的视图增强与节点级对比机制，提升了图对比学习的表达能力。

图对比学习的核心思想与计算机视觉中的对比学习高度一致：通过数据增强策略构建原始数据的两个不同视图，将双视图的实例映射到一个高维的潜在特征空间中，使得相似实例即正样本对的特征表示相互靠近，而差异较大的实例即负样本对的特征表示相互远离。通过这种互信息最大化机制，模型能够在无标签的情况下自动学习到具有判别性的节点表示。一个标准的图对比学习框架通常包含三个关键部分：图数据增强、正负样本对的定义和对比损失函数。图 2.4 展示了图对比学习的经典框架。

在图对比学习中，通常通过对原始图施加随机的扰动如随机删除节点、随机丢弃边、掩码节点特征以及子图采样，来生成两个结构不同但语义相关的增强视图，为后续对比学习提供基础。




图 2.4 图对比学习框架

如何选取有效的正负样本对，直接决定了图对比学习模型的性能。在节点级别的对比学习中，通常将同一个节点在不同视图下的表示视为正样本对。为了进一步融合局部的拓扑先验知识，还可以将节点的一阶邻居，或是共同属于同一个密集子图的节点定义为正样本。相应地，视图中其他不相关的节点则被统一视为负样本。

在完成增强图构建后，模型将两个增强视图分别输入至共享权重的图神经网络编码器中提取深层特征。在获得节点映射到潜在空间中的表示 $Z^{(1)}$ 和 $Z^{(2)}$ 后，模型通过优化对比损失函数来对齐表征。目前常用的对比损失是基于 InfoNCE 的改进形式。对于节点 v_i ，其图对比损失函数的一般形式为：

$$\mathcal{L}_{cl} = -\frac{1}{N} \sum_{i=1}^N \log \frac{\sum_{j \in Pos(i)} \exp(\text{sim}(Z_i^{(1)}, Z_j^{(2)}) / \tau)}{\sum_{j \in Pos(i)} \exp(\text{sim}(Z_i^{(1)}, Z_j^{(2)}) / \tau) + \sum_{k \in Neg(i)} \exp(\text{sim}(Z_i^{(1)}, Z_k^{(2)}) / \tau)} \quad (2.13)$$

其中， $Pos(i)$ 和 $Neg(i)$ 分别表示节点 v_i 的正样本集合和负样本集合； $\text{sim}(\cdot, \cdot)$ 表示余弦相似度，用于计算两个表示向量在潜在空间中的方向一致性； τ 为温度超参数，用于调节模型对难以区分的负样本的敏感程度。

通过最小化上述损失函数，模型能够在统一的嵌入空间中对齐来自不同视图下的特征语义。在本文后续的第三章和第四章中，图对比学习将作为最核心的特征融合模块，分别用于协同孤立与连通种子信息、融合低阶与高阶拓扑语义，提升社区划分的完整性与鲁棒性。

2.2.4 超图神经网络

前文所述的图卷积神经网络在处理复杂网络时，展现出了突出的局部特征提取能力。然而，GCN 的核心消息传递机制严格受限于两两相连的节点对关系，这使其在面对现实世界中广泛存在的多节点协同交互结构时，难以全面捕获网络真实的结构语义。为克服图神经网络在建模多节点关系时的表达局限，并在深度学习框架内建模这种高阶交互拓扑结构，超图神经网络（Hypergraph Neural Network, HGNN）应运而生。

与传统图结构不同，超图允许一条“超边”同时包含并连接任意数量的节点，从而能够将一个高阶交互群体作为一个整体，刻画多节点之间的协同关系。为了适配这一特殊的拓扑结构，HGNN 巧妙地利用超图的关联矩阵，设计了一种节点到超边到节点的两阶段信息传播机制。具体而言，HGNN 的单层卷积操作分为节点到超边的信息聚合和超边到节点的信息聚合两个步骤。

- **节点到超边的信息聚合：**在这一阶段，每一条超边会收集并聚合包含在超边中的所有节点的特征，以形成代表该高阶局部结构的超边特征。假设 $\hat{X}^{(l)}$ 为第 l 层超图卷积的输入节点特征矩阵，超边特征矩阵 $Y^{(l)}$ 的计算公式如下：

$$Y^{(l)} = W D_e^{-1} B^T \hat{X}^{(l)} \quad (2.14)$$

其中， B^T 表示关联矩阵的转置，用于将节点特征映射到超边上； D_e 是超边度矩阵， D_e^{-1} 相当于对超边内部的节点特征进行平均归一化； W 是超边权重对角矩阵，用于赋予不同高阶结构不同的初始重要性程度。

- **超边到节点的信息聚合：**获得超边的整体特征后，信息需要回传给节点，每个节点将收集并聚合它所参与的所有超边的特征，以此更新自身的表示。第 $l+1$ 层的节点特征集 $\hat{X}^{(l+1)}$ 更新过程可表示为：

$$\hat{X}^{(l+1)} = \sigma \left(D_v^{-1} B Y^{(l)} \hat{\Theta}^{(l)} \right) \quad (2.15)$$

其中， D_v 是节点度矩阵， D_v^{-1} 用于消除度数差异带来的聚合偏差； $\hat{\Theta}^{(l)}$ 为第

l 层中可训练的权重参数矩阵； $\sigma(\cdot)$ 为非线性激活函数。

将上述两个阶段合并，超图卷积层中节点特征的完整前向传播与更新公式可表示为：

$$\hat{X}^{(l+1)} = \sigma(D_v^{-1} B W D_e^{-1} B^T \hat{X}^{(l)} \hat{\Theta}^{(l)}) \quad (2.16)$$

通过转移矩阵 $D_v^{-1} B W D_e^{-1} B^T$ ，HGNN 实现了在多节点协同结构上的信息传递。

2.3 基序结构

网络基序又称模体 (motif) 是指在复杂网络中频繁出现的、具有特定拓扑结构的子图。基序反映了网络局部连接的规律性，是解析网络结构和功能的关键。R. Milo 等人^[51]首先提出网络基序的概念，明确指出基序是真实复杂网络中出现频率显著高于随机网络的特定局部连接模式。作为网络拓扑结构的基本构建模块，基序能够比单纯的单条边更能直观地反映网络局部的内在凝聚性与结构稳定性。

给定网络 $G = (V, E)$ ， $V = \{v_i | i = 1, 2, \dots, |V|\}$ ， $E = \{e_i | i = 1, 2, \dots, |E|\}$ ， $|V|$ 是节点的数量， $|E|$ 是边的数量。基序是在网络中出现的密集且互连的子图，具体表现为网络中连通分量构成的子图。如果一个具有 p 个节点和 q 条边的子图被视为基序时，可以表示为：

$$M_p^q = \{V_M, E_M\} \quad (2.17)$$

其中 $V_M \subseteq V$ 表示 p 个节点的集合， $E_M \subseteq E$ 表示 q 条边的集合，一般形式上认为 $p-1 \leq q \leq \frac{p(p-1)}{2}$ 。需要注意的是，仅仅依靠节点数 p 和边数 q 往往无法唯一确定基序的具体拓扑结构。例如，同样是包含 4 个节点和 3 条边的连通子图，既可以呈现为星状结构如图 2.5 中的 M3，也可以呈现为链状结构如图 2.5 中的 M5，二者在拓扑上互不包含、互不同构。为了简洁且精确地区分不同的高阶基序结构，本文采用全局统一的序列号 M_k 来进行表示。

在无向网络中，最受关注的高阶结构单元是由 3 个或 4 个节点构成的基序。如图 2.5 所示，网络中总共存在 8 种典型的三阶和四阶无向基序^[52]。




图 2.5 无向图中的三阶和四阶基序

针对特定的高阶基序，为了与原始节点的邻接矩阵 A 对齐，可以构造对应的基序邻接矩阵 A^M 。矩阵中的元素 A_{ij}^M 可以被表示为包含节点 v_i 和节点 v_j 的基序 M 实例的个数。在基序构建的过程中，节点 v_i 和节点 v_j 共现越多，二者的相似度越高。这种构造方式能够捕捉网络的高阶连通结构，打破了传统邻接矩阵仅能描述成对连接的局限，进一步丰富了网络拓扑的表达维度。图 2.6 的示例展示了基序邻接矩阵的构造过程。




图 2.6 三角基序邻接矩阵的构造

2.4 本章小结

本章对本文研究所涉及的预备知识与基础理论进行了系统梳理与详细介绍。首先,明确了社区检测的相关定义,重点介绍了社区划分质量的核心评价指标,包括模块度、标准化互信息以及 F-score 相似度。其次,系统地归纳了图深度学习的核心理论,包含图卷积神经网络、变分图自编码器、图对比学习以及超图神经网络的原理。最后,针对复杂网络的高阶基序展开探讨,分析了网络基序的定义以及基序邻接矩阵的构建方法。

第3章 基于连通种子结构和图对比学习的社区检测方法

3.1 引言

自然界和工程领域中存在的许多系统，如电力网络、交通系统和社交网络等，均可抽象为复杂网络模型进行分析。社区检测作为复杂网络分析的一项基础且核心的任务，有助于揭示网络的功能组织和隐藏结构，并在推荐系统和异常检测等领域具有广泛的应用价值。近年来，基于种子扩展的局部社区检测方法受到了研究者的广泛关注。这类方法通常利用极大团等高度内聚的子图结构作为初始种子社区，随后基于局部邻域信息进行种子社区扩展，以实现整个网络的划分^[52]。

尽管现有的基于种子扩展的方法在局部社区检测中取得了一定进展，但在处理真实复杂网络时仍面临两个局限。一方面，在种子生成阶段，现有方法往往将各个种子社区视为相互独立且没有连接的个体。这种将种子孤立化的处理方式，破坏了网络原本连接在一起的整体结构，使得原本属于同一个群体的节点被划分成互不相干的子集，导致社区的过度分割。另一方面，大多数现有方法在构建种子社区时依赖节点度等网络拓扑结构，未能充分地利用节点的高维属性信息。这种特征利用的不充分性，难以全面捕获节点间的深层语义关联，导致拓扑结构上不相连但深层语义高度一致的节点被划分到不同的社区中。综上所述，设计一种能有效融合多维特征构建种子社区并保留种子连通性的社区检测方法具有重要意义。

为了解决上述问题，本章提出了一种基于连通种子结构和图对比学习的社区检测方法（Community Detection Based on Connected Seed Structures and Graph Contrastive Learning, CSSGCL）。为了充分利用节点属性并提升初始种子质量，CSSGCL 首先引入变分图自编码器重构网络连边，将节点属性和连接关系映射到新的拓扑结构中，对网络结构进行增强。随后，在增强图中提取极大 k -plex 结构形成的内部凝聚的孤立种子社区，同时刻意保留种子社区间的边连接关系，以构建反映全局拓扑的连通种子社区。为了平衡局部特征与全局连通性，CSSGCL 利用图对比学习将孤立与连通种子社区的信息在统一的潜在表示空间中进行对齐与融合，进而指导高相似度种子社区的合并。最后，通过标签传播算法完成网络中剩余节点的分

配。本文在包括用户关系网络、科学出版物网络和网页超链接网络的多个真实世界数据集上的实验结果验证了该方法在提升社区检测精度与鲁棒性方面的优势。

3.2 模型和方法

本章提出的基于连通种子结构和图对比学习的社区检测方法 CSSGCL 旨在通过深度融合网络拓扑与节点属性生成种子社区，并在保留种子社区连通性的基础上进行高阶语义对齐，从而实现高精度的社区划分。如图 3.1 所示，该方法的整体框架主要由四个核心模块构成：网络拓扑增强，种子社区的构建，种子社区的合并以及种子社区的扩展。




图 3.1 CSSGCL 模型框架图

3.2.1 网络拓扑增强

在现实世界的复杂网络中，节点通常蕴含着丰富的高维属性信息，这些深层语义特征对于后续精准刻画节点关联、挖掘高质量的局部种子社区具有重要作用。原始的网络连边往往只能反映单一的拓扑关系，难以全面地体现节点间的属性关联。为了在后续挖掘种子社区时能够充分融合并利用节点的高维属性信息，我们在模型初始阶段设计了网络拓扑增强模块。该模块不仅将节点属性映射并补充到网络拓扑中，还针对真实网络因数据采集局限性而产生的噪声连接问题进行了优化，进而克服了拓扑结构不完整对种子社区提取的干扰。

本文引入变分图自编码器（Variational Graph Auto-Encoder, VGAE）来学习节点特征的潜在分布并重构网络拓扑。对于给定原始网络的邻接矩阵 A 与节点特征矩阵 X ，模型构建双层图卷积神经网络作为编码器。基于 2.2.2 节所述的图卷积传播机制，编码器首先通过共享权重学习基础节点嵌入，随后在第二层分别输出近似分布的均值 $\mu = GCN_{\mu}(X, A)$ 与对数方差 $\log \sigma = GCN_{\sigma}(X, A)$ 。

随后，基于获取的近似分布 $\mathcal{N}(\mu, \sigma)$ 采用重参数化技巧进行采样，这些样本共同构成了特征矩阵 Z 。最后，将 Z 输入到基于内积的图解码器中，计算并输出网络节点间的边连接概率重构矩阵 $\hat{M}$ ：

$$\hat{M} = Z \cdot Z^{\top} \quad (3.1)$$

在训练过程中，VGAE 的损失函数由两部分构成：用于衡量拓扑重构误差的交叉熵损失，以及用于约束估计分布逼近标准正态分布的 KL 散度。即：

$$loss_{VGAE} = L_{CE} - KL[q(\hat{M} | X, A) \parallel \prod_{i=1}^N \mathcal{N}(0, I)] \quad (3.2)$$

通过重构机制，生成的概率矩阵 $\hat{M}$ 能够将节点间的属性相似度映射为拓扑连接的可能性。为了实现拓扑增强，本方法避免了对重构矩阵的简单二值化处理，而是基于概率得分 $\hat{M}_{i,j}$ 设计了一种增删边策略：首先，在原始图 G 的真实边集 E 中，根据重构生成的概率矩阵 $\hat{M}$ 查找每条边的重要性得分。设定删边比例为 P_{rm} ，模型将得分最低的前 $P_{rm} \cdot |E|$ 条边从网络中删除，从而过滤掉可能存在的拓扑噪声或弱相关性连接。其次，在原始网络中未直接相连的节点对中，筛选出在 $\hat{M}$ 中具有极高连接概率的候选边。设定增边比例为 P_{add} ，模型将得分最高的前 $P_{add} \cdot |E|$ 条边补充到网络中，以此还原由于数据缺失而未被观测到，但属性高度一致的真实连接。

经过上述的增删操作，最终生成了一个增强后的网络图 $\hat{G}$ ，其对应的邻接矩阵记为 $\hat{A}$ 。与直接在原始图上进行社区检测相比，这种拓扑增强策略促使同一社区内的节点保持一致的连接模式，并将节点间的属性相似度映射为了拓扑连接。因此，

在增强图 $\hat{G}$ 上进一步挖掘 k -plex 结构, 能够缓解传统种子构建方法未能充分利用节点属性信息的难题, 生成高质量的种子社区。

3.2.2 种子社区的构建

在通过变分图自编码器获得增强图 $\hat{G}$ 后, 本节的目标是在此增强拓扑的基础上提取高质量的初始种子社区。与传统的极大团相比, k -plex 定义为图中的一个节点集 C , 其中任意节点成员 $i \in C$ 在该子图内的度均满足 $\deg_{G_s}(i) = |N(i) \cap C| \geq k$ 。作为一种放宽了严格全连通限制的高阶子图结构, k -plex 能够更灵活地刻画复杂网络中真实社区的内部紧密连接特性。

为了精确捕捉网络局部的强内聚关系, 模型首先在增强图 $\hat{G}$ 上利用分支搜索 (Branch-and-Search) 算法^[54]寻找极大 k -plex 结构。提取出的每一个极大 k -plex 子图被视为一个独立的局部社区中心。这些相互独立、内部密集的结构集合构成了孤立种子社区, 可以表示为 $G^P = \{V^P, E^P\}$, 其中, V^P 和 E^P 分别代表孤立种子社区中的节点集合与边集合。与之对应的邻接矩阵记为 $A^P \in \mathbb{R}^{n \times n}$, 其中节点总数 $n = N - n_{iso}$, N 为网络总节点数, n_{iso} 为在 k -plex 提取过程中产生的孤立节点数量。

然而, 在构建这些孤立种子社区的过程中, 由于 k -plex 算法严格的局部密度约束, 原始的连通网络不可避免地失去连通性。这一过程虽然筛选出了极高密度的核心单元, 但切断了这些核心单元之间客观存在的拓扑连接关系。这种处理方式使得原本可能属于同一真实语义群体的种子社区被分割为互不相关的独立实体, 导致后续在分配社区标签时造成标签的碎片化与标签数量的增加, 从而引发过度分割问题。

为了弥补孤立种子在全局拓扑连接上的缺失, 并遏制过度分割现象, 模型进一步构建了连通种子社区如图 3.2 所示。其核心逻辑在于: 在确定了核心种子节点的基础上, 保留了它们在原始网络中的真实连接关系。具体而言, 模型从原始连通网络 G 中剔除那些未能进入任何 k -plex 结构的孤立节点集合 V_{iso} , 仅保留由核心种子节点组成的连通分量, 从而获得连通种子社区图 $G^C = \{V^C, E^C\}$, 节点集合

$V^C = V - V_{iso}$ ，而 E^C 包含了这些种子节点之间所有的原始连边，对应的邻接矩阵记为 $A^C \in \{0,1\}^{n \times n}$ 。

通过上述操作，CSSGCL 构建了描述局部高内聚性的孤立种子视图 G^P 以及保留全局连接关系的连通种子视图 G^C 。这两种不同视角的拓扑结构将被同步输入后续的图对比学习模块，实现局部与全局特征的对齐与融合。




图 3.2 种子社区的构建

3.2.3 种子社区的合并

在构建孤立种子社区图 G^P 与连通种子社区图 G^C 之后，接下来的核心任务是将这两种既高度关联又存在局部差异的拓扑视图进行有效对齐，指导相似种子社区的合并。为了充分挖掘这两种视图在局部与全局上的一致性信息，本章设计了一个包含图卷积模块和聚类模块的图对比学习框架，如图 3.3。

图卷积神经网络能够通过聚合邻居信息有效地将网络结构映射到低维潜在空间。在本模块中， G^P 和 G^C 被视为通过图增强获得的两个独立视图。在输入编码器之前，首先对孤立种子社区的邻接矩阵 A^P 和连通种子社区的邻接矩阵 A^C 进行对称归一化处理，分别得到 $A^{P'}$ 和 $A^{C'}$ 。随后，将这两个视图输入到一个参数共享的 GCN 编码器中以获取节点表示。以孤立种子社区为例，其第 l 层的隐藏特征表示更新规

则如下：

$$H_l^P = \sigma(A^{P'} H_{l-1}^P W_l) \quad (3.3)$$

其中, W_l 为第 l 层的权重矩阵, $\sigma(\cdot)$ 为激活函数, 初始输入 H_0^P 为节点属性矩阵 X^P 。

经过多层图卷积后, 可以得到孤立种子社区的嵌入表示 H^P 以及连通种子社区的嵌入表示 H^C 。

虽然 G^P 和 G^C 反映了网络本质结构, 但两者在拓扑上存在差异, 例如在 G^C 中连通的节点在 G^P 中可能断开。为了保持嵌入表示的一致性特征, 并减少拓扑噪声的干扰, 模型最小化嵌入矩阵乘积与单位矩阵 I 之间的差异, 以此使得 H^P 和 H^C 尽可能相似:

$$\mathcal{L}_{sim} = \|H^C H^P - I\|_F^2 \quad (3.4)$$

接下来, 本节引入多层感知机 (MLP) 对嵌入特征进行非线性映射, 并通过 Softmax 函数输出节点归属于各个社区的分配概率。令 $Z^P, Z^C \in \mathbb{R}^{n \times K}$ 为两个视图的聚类指示矩阵, 其中 K 为聚类数量, 其计算方式为:

$$Z^P = \text{softmax}(\text{MLP}(H^P)), \quad Z^C = \text{softmax}(\text{MLP}(H^C)) \quad (3.5)$$

理想的社区划分通常表现为指示矩阵的高度稀疏性, 这是因为稀疏的分配状态意味着节点具有明确的社区归属。因此, 模型在目标函数中引入了稀疏性约束损失:

$$\mathcal{L}_{spr} = \|Z^P\|_1 + \|Z^C\|_1 \quad (3.6)$$

为了在无标签情况下实现高质量的表示对齐, 模型引入了基于 InfoNCE 的改进对比学习机制。在节点级对比学习中, 为了充分利用局部先验知识, 本方法将同一节点的第一阶邻居以及属于同一个 k -plex 的节点共同定义为正样本集 Pos , 而其余节点作为负样本, 对比学习框架如图 3.3 所示。连通与孤立视图之间的节点级对比损失 $\mathcal{L}_{cl}$ 设计如下:

$$\mathcal{L}_{cl} = -\frac{1}{n} \sum_{i=1}^n \log \frac{(\sum_{j \in Pos} e^{\text{sim}(Z_i^P, Z_j^C)} + \sum_{j \in Pos} e^{\text{sim}(Z_i^C, Z_j^P)}) / |Pos|}{\sum_{i'=1, i' \neq i}^n e^{\text{sim}(Z_i^P, Z_{i'}^P)} + \sum_{i'=1}^n e^{\text{sim}(Z_i^C, Z_{i'}^C)}} \quad (3.7)$$

其中, $\text{sim}(\cdot, \cdot)$ 表示余弦相似度。该损失确保了同一社区内节点在表示空间中的高度聚集。

为了在全局宏观维度对齐两个视图的语义结构, 模型在聚类层面上最大化了两个指示矩阵转置之间的互信息 $I(Z^{P^T}, Z^{C^T})$, 总的融合对比损失定义为:

$$\mathcal{L}_{fus} = \mathcal{L}_{cl} + I(Z^{P^T}, Z^{C^T}) \quad (3.8)$$

综合上述一致性约束、稀疏性约束以及对比损失, CSSGCL 模型在训练阶段的总体目标函数定义为:

$$\mathcal{L} = \mathcal{L}_{spr} + \mathcal{L}_{sim} + \alpha \mathcal{L}_{fus} \quad (3.9)$$

其中, α 为调节对比学习模块权重的超参数。通过最小化该目标函数, 网络能够实现参数优化。最终, 对于所有非孤立节点, 其融合后的社区标签分配通过结合两个视图的预测概率来确定:

$$y_i^{non-iso} = \text{argmax}(Z_{ij}^P + Z_{ij}^C) \in \{1, 2, \dots, K\} \quad (3.10)$$




图 3.3 CSSGCL 中图对比学习的框架图

3.2.4 种子社区的扩展

通过上一小节的图对比学习模块, CSSGCL 已经为网络中的核心种子节点分配了社区标签。然而, 在初始极大 k -plex 种子提取阶段, 网络中仍有一部分处于边缘或连接稀疏区域的节点即孤立节点集合 V_{iso} 尚未被划定社区归属。模型最终的任务

是将这些未分配标签的剩余节点划分到最合适的社区中。

为了实现符合网络拓扑特征的社区扩展，本章引入了基于启发式规则的标签传播算法。该扩展策略的核心思想在于，网络中节点的社区归属主要受其局部邻居节点的影响。通常情况下，具有较高节点度的核心节点倾向于维持其原有的社区标签；而处于边缘地位的节点则容易被其周围的高影响力节点所同化^[55]。节点 i 的标签更新公式为：

$$y_i^{iso} = \arg \max_k C_{ik}^{num} \quad (3.11)$$

其中， C_{ik}^{num} 表示节点 i 的邻居节点中属于第 k 个社区的节点数量。在实际扩展计算中，模型不仅考虑特定标签的出现频次，还会聚合邻居节点的度数信息，并选取度数总和最显著的社区标签作为节点 i 的候选标签。

在实际的标签分配过程中，算法严格遵循以下判定规则：（1）唯一主导标签：如果根据上式计算出的最大值对应的候选标签 y_i^{iso} 是唯一的，则直接将该标签赋予节点 i 。（2）多标签冲突：如果存在多个社区标签具有相同的最大邻居影响力得分，算法将从这些得分最高的候选标签中随机选择一个赋予节点 i 。

上述标签传播过程将在整个网络的孤立节点集合中进行迭代更新，直至网络中所有的节点都被赋予了明确的社区标签。至此，CSSGCL 完成了从拓扑增强、双视图特征融合到社区扩展的完整实现，最终输出整个网络 G 的高质量社区划分结果

$$Y = Y^{non-iso} \cup Y^{iso}。$$

3.3 实验验证与结果分析

本节旨在评估所提出的 CSSGCL 方法在复杂网络社区检测任务中的有效性与鲁棒性。实验基于多个不同领域、不同规模且具有不同属性特征的真实世界网络数据集展开，并与当前领域内多个先进的基准算法进行了对比分析。

3.3.1 数据集与评价指标介绍

为了从多维度客观验证 CSSGCL 方法的性能，本文选取了 12 个经典且被广泛

使用的真实世界网络数据集进行实验。这些数据集涵盖了社交网络、引文网络以及网页链接网络等多种场景，其详细的统计信息包括节点数、边数、社区数以及属性维度如表 3.1 所示。

表 3.1 数据集介绍

数据集	节点数	边数	社区数	属性数
Karate	34	78	2	/
Word adjacencies	112	425	2	/
Football	115	613	12	/
Live Journal	1018	7149	36	/
DBLP	10029	29400	326	/
Cornell	195	186	5	1703
Texas	187	328	5	1703
Washington	230	446	5	1703
Wisconsin	265	530	5	1703
Cora	2708	5429	7	1433
Citeseer	3312	4732	6	3703
Pubmed	19729	44338	3	500

根据网络是否具有高维属性信息以及属性信息的类型，这 12 个数据集可以划分为以下几类：

- **无属性基准网络：**此类数据集包括 Karate^[56]、Word adjacencies^[57]、Football^[11]、Live Journal^[54]以及 DBLP^[58]。这些网络仅包含拓扑连接关系，并在拓扑结构上表现出明显的社区聚集特征。其中，Karate 和 Live Journal (LJ) 分别描述了线下空手道俱乐部与在线社交平台中个体成员之间的交互关系；Football 记录了美国大学橄榄球联盟的赛程安排，其中节点代表球队，边代表球队之间的对阵关系；Word adjacencies (Adjnoun) 是基于查尔斯·狄更斯小说《大卫·科波菲尔》中常用形容词和名词构成的词汇邻接网络；DBLP 则是一个典型的科学协作网络，每个节点代表一位科研工作者，边表示两名学者之间存在合作发文记录。其中 Karate、Adjnoun 和 Football 常被用于测试算法在小规模网络上的拓扑捕捉能力。

- **网页链接网络**：包括 Cornell、Texas、Washington 和 Wisconsin 数据集^[59]。这些数据集分别描述了来自康奈尔大学、得克萨斯大学、华盛顿大学和威斯康星大学的学生、教职工及项目组相关联的网页集合。在这些网络中，节点代表具体的网页页面，边代表网页之间存在的超链接关系。除了上述拓扑连接外，网络中的节点还具备基于网页文本内容提取的词袋特征。由于不同高校网页的结构和内容侧重点不同，它们表现出各自特有的特征分布规律。
- **引文网络**：包括 Cora、Citeseer 和 PubMed 数据集^[60]。其中，Cora 和 Citeseer 涵盖了计算机科学领域的学术文献，PubMed 则专注于糖尿病相关的医学文献。在这类网络中，节点代表独立的学术论文，边代表论文之间的相互引用关系，而节点属性则由基于论文摘要或正文内容构建的 TF-IDF 词频特征表示。这些网络兼具复杂的引文拓扑连接与高维的文本语义属性，能够验证算法对结构与属性特征的融合能力。

为了方便描述，将数据集中标准的社区划分定义为 C^* ，算法最终生成的社区划分集合定义为 C 。为了全面、客观地衡量模型的划分质量，本次实验共选取了四种在社区检测中常用的评价标准来综合衡量模型的社区划分质量：

(1) 标准化互信息(Normalized Mutual Information, NMI)：该指标利用信息论思想来评估模型输出与标准社区划分之间的全局相似程度，能够有效避免社区数量差异带来的评估偏差。其计算公式为：

$$NMI = \frac{2 \times I(C^*, C)}{H(C^*) + H(C)} \quad (3.12)$$

其中， $I(C^*, C)$ 表示标准划分与预测划分之间的互信息， $H(\cdot)$ 表示信息熵。

(2) 准确率 (Accuracy, ACC)：该指标用于衡量聚类结果与真实标签之间的节点级匹配程度，通过将算法预测的社区标签 $\bar{Y}$ 与网络真实的标签 Y 进行对比来计算。其计算公式如下式所示：

$$ACC(Y, \bar{Y}) = \frac{\sum_{i=1}^N \delta(Y_i, \bar{Y}_i)}{N} \quad (3.13)$$

其中， N 为网络中的节点总数， Y_i 和 $\bar{Y}_i$ 分别代表节点 i 的真实标签和模型预测标签。

值得注意的是，由于无监督聚类输出的社区可能与真实标签存在排列错位，函数 $\text{map}(\cdot)$ 通过匈牙利匹配算法^[61]实现，用于寻找预测标签与真实标签之间的最优排列映射，以最大化两者的匹配度。 $\delta(x, y)$ 为指示函数，当且仅当 $x = y$ 时其值为 1，否则为 0。

(3) F-Score 相似度与 Jaccard 相似度：这两个指标结合了精确率和召回率的思想，用于衡量匹配社区对之间的重叠程度。综合相似度得分的计算公式为：

$$S(C^*, C) = \frac{1}{2|C^*|} \sum_{C_i^* \in C^*} \max_{C_j \in C} \delta(C_i^*, C_j) + \frac{1}{2|C|} \sum_{C_j \in C} \max_{C_i^* \in C^*} \delta(C_i^*, C_j) \quad (3.14)$$

其中的 $\delta(\cdot)$ 为相似度度量函数。当采用 F-score 或 Jaccard 作为 δ 函数时，即可分别得到 F1 相似度和 Jaccard 相似度得分。上述指标的取值范围均在 0 到 1 之间，得分越接近 1，表明算法检测出的社区结构与真实情况越吻合，即模型的划分性能越好。

3.3.2 实验设置

本实验在搭载了 Intel(R) Xeon(R)处理器与 NVIDIA RTX 4090 显卡的服务器上对模型进行训练。我们所提出的 CSSGCL 方法及相关基线方法均基于 Python 3.8 编程语言开发，并采用 PyTorch 1.7 开源深度学习框架进行核心代码的构建与训练。在模型优化阶段，CSSGCL 统一采用 Adam 优化器进行网络参数的迭代更新，全局初始学习率被设定为 $5e-3$ ，同时用于调节图对比学习模块权重的正则化超参数 α 在所有测试数据集上均固定设置为 1。为了避免图卷积神经网络的过平滑问题，本文将图卷积神经网络的层数设定为 2，隐藏层维度设定为 128。此外，为确保性能对比的严谨性，所有参与比较的基准算法均严格遵循其原论文中所设置的最优超参数进行独立配置与复现。

3.3.3 对比方法

为了全面客观地评估本章提出的 CSSGCL 的有效性，实验选取了 12 种在复杂网络社区检测与图表示学习领域具有代表性的先进算法作为对比基线。根据算法在特征利用方式以及对标签依赖程度的不同，这些对比算法被划分为以下三大类：

(1) 传统无监督社区检测方法。此类方法通常仅依赖于原始网络的拓扑结构如边连接、密度等进行节点聚类或网络划分，不涉及节点属性信息的高维融合。

Louvain^[8]: 一种基于模块度优化的经典启发式网络划分算法，通过不断最大化每个社区的模块度得分来实现网络的快速划分。

VGAE+Louvain: 本文设置的一种组合基线算法。首先利用变分图自编码器对原始图进行重构增强，随后在重构图上应用 Louvain 算法进行社区划分，以验证充分利用节点属性的重要性。

Infomap^[23]: 一种基于信息论的经典社区检测算法，其核心思想是通过最小化随机游走在图上移动轨迹的描述长度来检测社区边界。

DeepWalk^[32]: 基于随机游走的网络表示学习算法，通过在图拓扑上生成随机游走序列，并结合自然语言处理中的 Skip-gram 模型来学习节点的低维表示向量。

Node2Vec^[62]: DeepWalk 的改进版本，通过引入两个超参数来平衡广度优先搜索与深度优先搜索，从而生成有偏的随机游走路径，更好地保留了网络的局部与全局结构特征。

(2) 基于半监督图神经网络的社区检测方法。此类方法利用了图神经网络强大的表征能力，能够同时编码网络的拓扑结构与节点属性信息。虽然图神经网络通常依赖部分已知标签进行半监督训练，但该类别同样包含了一些针对无监督聚类任务优化的先进变体。

GCN^[34]: 标准的图卷积神经网络，利用谱图卷积的一阶近似机制，通过聚合局部邻居的图结构与节点特征来学习隐藏层的高维表示。

SGCN^[63]: 一种面向属性网络的无监督社区检测变体。该方法通过识别结构中心节点并向其邻居扩展来构建平衡的训练集，从而指导 GCN 更好地融合拓扑与属性信息。

KPGN^[35]: 一种基于极大 k -plex 的图神经网络方法。该方法首先利用 k -plex 结构提取初始种子社区，随后构建 GraphSAGE 模型以捕获节点间的深层关联。同时，在 GraphSAGE 中应用了节点采样策略来降低图神经网络的过平滑问题，最终确定节点的社区归属。

VGAE+KPGN: 本文设置的另一种组合基线算法。先使用 VGAE 重构原始网络

连边，再应用 KPGN 算法进行后续划分。

(3) 基于自监督图表示学习的社区检测方法。此类方法代表了当前图表示学习的前沿方向，主要依赖图对比学习范式，能够在不依赖人工标签的情况下自动学习出极具判别力的节点嵌入，是本章 CSSGCL 模型主要对比方法。

AFGRL^[64]：一种无需生成数据增强视图的图对比学习框架。该模型利用 KNN 捕获局部结构信息，通过聚类捕获全局信息，并为每个节点自适应地选择最优的正样本进行对比学习。

GraphCL^[49]：经典的图对比学习框架。该方法设计了节点丢弃和边扰动等多种图数据增强策略，通过拉近同一节点在两个增强视图下的嵌入表示，并推开不同节点的表示来进行模型参数的自监督优化。

CSGCL^[65]：一种基于社区强度增强的图对比学习方法。该模型利用定义的社区强度指标来指导节点属性掩码和边丢弃操作，并结合动态的图对比学习策略来调整对比优化目标。

3.3.4 主要实验结果

为了验证 CSSGCL 模型的有效性，本节在 12 个真实世界数据集上对其与 12 种基线方法进行了性能比较。各方法在标准化互信息 NMI、准确率 ACC、F-score 相似度以及 Jaccard 相似度四个评价指标上的具体表现如表 3.2 至表 3.5 所示。

从全局对比结果来看，CSSGCL 方法在不同规模和特征分布的数据集上表现出了稳定且优异的社区检测能力。特别是在衡量划分结构与真实标签吻合度的核心指标 NMI 上，CSSGCL 在 12 个数据集集中的 8 个数据集上取得了最高得分，验证了该方法在捕捉网络底层真实社区模块方面的优越性。在结构相对简单且标准的 Karate 数据集中，包括 CSSGCL 和 KPGN 在内的多种先进方法均实现了 100% 的完全准确划分。在 Cora 数据集上，CSSGCL 在 NMI、ACC 和 F-Score 指标上均取得了第二名的优异成绩，且与排名第一的方法差距极小，进一步验证了其在挖掘紧密社区结构方面的突出性能。

Adjnoun 数据集上的比较尤为值得关注。Adjnoun 是一个典型的密集网络，节点之间存在大量冗余的连接边，这种复杂的连通性往往会掩盖真实的社区结构，导

致 Louvain 和 KPGN 等方法的社区检测性能大幅下降。相比之下, CSSGCL 在该数据集上的 NMI、ACC 和 F-Score 指标均实现了提升。这主要归功于模型引入了变分图自编码器模块, 该模块能够结合节点属性分布精准识别并过滤掉冗余噪声连接, 重构出清晰的网络拓扑。同时, 实验中 VGAE+KPGN 组合相比单纯 KPGN 实现了性能提升, 也从侧面印证了 VGAE 拓扑增强策略的有效性。

与 Louvain、Infomap 以及 DeepWalk 等仅依赖网络拓扑结构的传统无监督方法相比, CSSGCL 在网页链接网络如 Cornell 与 Texas 等和引文网络如 Citeseer 与 PubMed 上的表现具有性能优势。实验结果表明, 仅仅依靠结构信息难以全面刻画复杂的交互关系; 而 CSSGCL 能够通过图神经网络深度融合拓扑结构和节点的高维属性信息, 增强了模型对潜在社区的发现能力, 提高了社区检测的准确率。

与基于 k -plex 的半监督图神经网络方法 KPGN 相比, CSSGCL 展现出了更强的鲁棒性。KPGN 仅依赖孤立的 k -plex 结构作为种子, 容易导致社区的过度分割。而 CSSGCL 引入了保留原始边界的连通种子社区视图, 并利用图对比学习机制将局部内聚性与全局连通性进行了深度对齐与融合, 实现了高质量的社区合并与扩展, 避免了社区的过度分割问题。此外, 相较于 GraphCL 和 AFGRL 等图对比学习框架, CSSGCL 取得了更优的成绩, 这表明针对社区检测任务专门设计的结构导向型视图构造策略, 相较于传统的随机数据增强策略具有更强的针对性与判别力。

表 3.2 NMI 的实验结果对比

Method	Karate	Adjnoun	Football	LJ	DBLP	Cornell	Texas	Washington	Wisconsin	Cora	Citeseer	PubMed
Louvain	0.521	0.006	0.663	0.947	0.803	0.158	0.203	0.136	0.159	0.072	0.046	0.078
VGAE+Louvain	0.587	0.276	0.704	0.963	0.845	0.321	0.336	0.198	0.198	0.256	0.245	0.236
Infomap	0.612	0.004	0.911	0.608	0.505	0.209	0.168	0.187	0.192	0.476	0.405	0.264
DeepWalk	0.579	0.267	0.883	0.387	0.116	0.079	0.057	0.059	0.071	0.337	0.105	0.166
Node2Vec	0.602	0.337	0.905	0.402	0.339	0.085	0.064	0.143	0.158	0.448	0.249	0.284
GCN	0.648	0.347	0.921	0.695	0.423	0.401	0.479	0.488	0.413	0.545	0.434	0.250
KPGN	1.000	0.049	0.938	0.910	0.835	0.474	0.488	0.481	0.451	0.591	0.534	0.411
VGAE+KPGN	1.000	0.445	0.943	0.923	0.846	0.487	0.507	0.487	0.463	0.606	0.548	0.452
SGCN	1.000	0.416	0.941	0.912	0.851	0.337	0.485	0.403	0.446	0.614	0.515	0.408
GraphCL	0.957	0.204	0.838	0.768	0.745	0.322	0.394	0.432	0.402	0.461	0.444	0.310
AFGRL	0.924	0.303	0.879	0.853	0.805	0.453	0.495	0.479	0.447	0.578	0.532	0.428
CSGCL	1.000	0.357	0.948	0.913	0.835	0.537	0.569	0.495	0.472	0.648	0.547	0.423
CSSGCL(ours)	1.000	0.489	0.951	0.921	0.867	0.551	0.585	0.502	0.467	0.631	0.578	0.436

表 3.3 ACC 的实验结果对比

Method	Karate	Adjnoun	Football	LJ	DBLP	Cornell	Texas	Washington	Wisconsin	Cora	Citeseer	PubMed
Louvain	0.500	0.179	0.674	0.947	0.803	0.154	0.197	0.124	0.159	0.072	0.046	0.075
VGAE+Louvain	0.563	0.204	0.701	0.953	0.826	0.214	0.237	0.189	0.206	0.103	0.096	0.135
Infomap	0.794	0.509	0.739	0.610	0.056	0.092	0.069	0.061	0.059	0.004	0.013	0.053
DeepWalk	0.882	0.268	0.665	0.478	0.248	0.318	0.326	0.350	0.287	0.467	0.362	0.619
Node2Vec	0.894	0.271	0.685	0.427	0.433	0.327	0.346	0.367	0.304	0.476	0.374	0.637
GCN	0.875	0.404	0.767	0.584	0.465	0.463	0.571	0.549	0.556	0.815	0.703	0.790
KPGN	1.000	0.046	0.918	0.745	0.824	0.724	0.681	0.787	0.745	0.811	0.782	0.812
VGAE+KPGN	1.000	0.235	0.921	0.824	0.856	0.736	0.701	0.813	0.758	0.867	0.795	0.823
SGCN	1.000	0.719	0.914	0.864	0.835	0.625	0.674	0.643	0.656	0.875	0.759	0.812
GraphCL	0.905	0.467	0.788	0.745	0.534	0.539	0.484	0.583	0.619	0.705	0.712	0.697
AFGRL	0.956	0.625	0.857	0.887	0.723	0.665	0.575	0.673	0.739	0.716	0.776	0.757
CSGCL	1.000	0.652	0.928	0.923	0.805	0.737	0.718	0.794	0.755	0.887	0.775	0.813
CSSGCL(ours)	1.000	0.748	0.931	0.938	0.847	0.743	0.719	0.835	0.768	0.867	0.794	0.824

表 3.4 F-Score 的实验结果对比

Method	Karate	Adjnoun	Football	LJ	DBLP	Cornell	Texas	Washington	Wisconsin	Cora	Citeseer	PubMed
Louvain	0.743	0.239	0.742	0.709	0.532	0.167	0.164	0.114	0.126	0.054	0.032	0.057
VGAE+Louvain	0.756	0.267	0.762	0.721	0.513	0.206	0.345	0.184	0.276	0.204	0.217	0.187
Infomap	0.524	0.002	0.813	0.546	0.467	0.165	0.134	0.123	0.147	0.453	0.384	0.223
DeepWalk	0.443	0.135	0.742	0.304	0.104	0.063	0.054	0.047	0.013	0.206	0.071	0.104
Node2Vec	0.504	0.206	0.845	0.371	0.324	0.075	0.047	0.104	0.132	0.427	0.209	0.237
GCN	0.684	0.498	0.723	0.731	0.536	0.385	0.374	0.425	0.312	0.468	0.376	0.204
KPGN	1.000	0.503	0.841	0.805	0.583	0.481	0.448	0.437	0.357	0.476	0.468	0.305
VGAE+KPGN	1.000	0.521	0.891	0.813	0.648	0.513	0.463	0.451	0.373	0.537	0.478	0.343
SGCN	1.000	0.516	0.924	0.816	0.604	0.346	0.476	0.421	0.368	0.504	0.412	0.364
GraphCL	0.856	0.195	0.766	0.668	0.678	0.367	0.435	0.405	0.387	0.401	0.387	0.304
AFGRL	0.926	0.423	0.687	0.754	0.647	0.408	0.446	0.384	0.378	0.578	0.532	0.428
CSGCL	1.000	0.566	0.917	0.876	0.634	0.487	0.496	0.441	0.478	0.614	0.506	0.589
CSSGCL(ours)	1.000	0.543	0.936	0.836	0.675	0.507	0.432	0.445	0.421	0.603	0.564	0.566

表 3.5 Jaccard 的实验结果对比

Method	Karate	Adjnoun	Football	LJl	DBLP	Cornell	Texas	Washington	Wisconsin	Cora	Citeseer	PubMed
Louvain	0.644	0.136	0.662	0.691	0.431	0.154	0.104	0.087	0.106	0.007	0.003	0.014
VGAE+Louvain	0.601	0.243	0.664	0.674	0.423	0.156	0.243	0.174	0.254	0.134	0.175	0.124
Infomap	0.443	0.001	0.765	0.435	0.345	0.104	0.113	0.086	0.106	0.366	0.324	0.214
DeepWalk	0.402	0.103	0.713	0.213	0.096	0.051	0.046	0.023	0.028	0.326	0.103	0.085
Node2Vec	0.465	0.203	0.821	0.352	0.316	0.073	0.042	0.098	0.165	0.432	0.297	0.201
GCN	0.664	0.254	0.685	0.603	0.321	0.103	0.154	0.164	0.175	0.453	0.321	0.216
KPGN	1.000	0.501	0.823	0.756	0.556	0.326	0.410	0.415	0.321	0.416	0.481	0.206
VGAE+KPGN	1.000	0.531	0.876	0.836	0.578	0.351	0.424	0.387	0.354	0.463	0.451	0.321
SGCN	1.000	0.503	0.869	0.786	0.604	0.324	0.489	0.406	0.354	0.487	0.706	0.346
GraphCL	0.806	0.146	0.658	0.604	0.504	0.324	0.335	0.246	0.287	0.327	0.304	0.246
AFGRL	0.904	0.386	0.546	0.706	0.647	0.356	0.386	0.356	0.305	0.468	0.476	0.354
CSGCL	1.000	0.524	0.896	0.846	0.634	0.421	0.467	0.354	0.406	0.503	0.438	0.486
CSSGCL(ours)	1.000	0.558	0.872	0.856	0.654	0.394	0.497	0.431	0.432	0.515	0.491	0.534

3.3.5 消融实验

为了验证 CSSGCL 方法中各个核心模块对最终社区检测性能的具体贡献, 本节在 Football、DBLP 和 Cornell 三个代表性数据集上进行了消融实验。实验主要针对网络拓扑增强模块和图对比学习模块中的正样本采样策略进行拆解分析。

具体而言, 本文设计了 CSSGCL 方法的三种变体:

- CSSGCL-V: 移除了基于 VGAE 的网络拓扑增强模块, 直接在原始网络图上提取种子社区并进行后续的图对比学习。
- CSSGCL-C: 保留了拓扑增强模块, 但将其核心的图对比融合损失函数 $\mathcal{L}_{fus}$ 替换为标准的 InfoNCE 损失函数, 不再强调基于 k -plex 和一阶邻居的正样本采样策略。
- CSSGCL-V-C: 同时移除了 VGAE 拓扑增强模块并将对比损失替换为标准 InfoNCE 损失, 作为最基础的对照模型。

此外需要特别说明的是, 如果在 CSSGCL 中移除连通种子社区, 模型实际上退化为 VGAE+KPGN 基线模型。

在三个数据集上的消融实验结果如表 3.6 所示, 完整的 CSSGCL 模型的性能在所有评价指标上均为最优。通过对变体方法的分析, 可以得出以下结论:

(1) 观察 CSSGCL-V 的表现可以发现, 在移除 VGAE 模块后, 模型在所有测试数据集上的性能均出现了下降。这表明 VGAE 在消除网络冗余噪声边、补全缺失连边以及融合节点属性方面发挥了关键的作用, 它为后续提取高质量、高一致性的 k -plex 种子社区提供了拓扑基础。

(2) 与完整模型相比, CSSGCL-C 变体的性能也出现了明显的衰退。例如在三个主要数据集上, 采用标准 InfoNCE 的模型 NMI 指标分别下降了 1.58%、4.03% 和 5.36%。这一数据验证了本文所设计的正样本采样策略即将同一 k -plex 内的节点以及一阶邻居节点视为正样本的合理性和有效性, 它比通用的对比损失更能敏锐地捕捉并保留局部的社区拓扑先验知识。

(3) 当同时剥离这两个核心组件即 CSSGCL-V-C 变体时, 社区检测的各项性能指标跌至最低。这表明 VGAE 拓扑增强与双视图图对比学习之间并非简单的线

性叠加，而是存在着相互促进与协同增强作用。高质量的增强图作为对比学习提供了更具判别力的视图输入，而对比融合又最大化地利用增强图的结构信息。

表 3.6 消融实验结果

Method	Football			DBLP			Cornell		
	NMI	F-Score	Jaccard	NMI	F-Score	Jaccard	NMI	F-Score	Jaccard
CSSGCL	0.951	0.936	0.872	0.867	0.675	0.654	0.551	0.507	0.394
CSSGCL-V	0.935	0.913	0.769	0.746	0.532	0.413	0.518	0.492	0.367
CSSGCL-C	0.936	0.913	0.770	0.732	0.536	0.413	0.521	0.491	0.379
CSSGCL-V-C	0.907	0.891	0.731	0.625	0.429	0.402	0.512	0.473	0.352

3.3.6 模型收敛性分析

为了验证所提出的 CSSGCL 模型在图对比学习与优化训练过程中的稳定性，本节在 Football、DBLP 和 Cornell 数据集上分别进行了收敛性分析。本文记录并绘制了模型在反向传播训练过程中，各项损失函数值随迭代次数增加的变化曲线，如图 3.4 所示。

在收敛性评估中，本文不仅追踪了模型的总体目标损失 $\mathcal{L}$ ，还单独记录了构成总损失的各个子模块损失项，包括聚类指示矩阵的稀疏性损失 $\mathcal{L}_{spr}$ 、视图间嵌入表示的一致性对齐损失 $\mathcal{L}_{sim}$ 以及基于节点和聚类互信息的对比融合损失 $\mathcal{L}_{fus}$ 。




图 3.4 收敛性曲线

观察曲线变化可以发现,在训练初期,总体目标损失 $\mathcal{L}$ 以及各项子损失尤其是对比融合损失和一致性损失均呈现出快速下降的趋势。这表明模型通过梯度下降快速调整网络权重以对齐特征空间,能够捕捉到孤立视图与连通视图之间的结构差异。在经过最初几十次的快速迭代后,各项损失曲线下下降趋势迅速变缓,并最终收敛到一个稳定状态。除了在局部极小值附近存在的微小数值波动外,整体收敛曲线呈现出逐渐平稳的趋势。

上述现象表明了本文设计的联合损失函数公式(3.9)具有良好的优化稳定性与收敛特性。CSSGCL 不仅能够在无标签数据的自监督学习环境下实现高效的特征对齐,而且具备优异的收敛性与训练鲁棒性,能够可靠地输出高质量的社区划分结果。

3.3.7 超参数分析

CSSGCL 模型中包含了几个关键的超参数,它们的取值在一定程度上会影响模型在不同类型数据集上的表现。为了测试模型的鲁棒性并探究最优超参数,本节在 Football、DBLP 和 Cornell 三个数据集上分别针对图对比学习权重 α 、 k -plex 结构参数 k 与 bound 以及拓扑增强增边概率 P_{add} 与删边概率 P_{rm} 进行了详细的分析。

(1) 图对比学习权重参数 α 的影响

参数 α 主要用于调节总体损失函数公式(3.9)中对比融合损失模块的权重比例。在保持其他实验设置不变的前提下,通过改变 α 的值可以观察到社区检测结果的变化。图 3.5 结果表明,随着 α 值的逐渐增加,模型在三个数据集上的聚类性能呈现出稳步上升的趋势,并在 $\alpha=1$ 时达到最佳表现。这进一步印证了图对比学习模块在特征对齐与指导社区合并过程中的核心驱动作用。




图 3.5 超参数 α 对实验结果的影响

(2) k -plex 规模参数 k 与 bound 的影响

参数 k 和 bound 决定了初始极大 k -plex 种子社区的密度与最小规模。在实验中，本文采用控制变量法即固定一个参数并调整另一个对这两个参数进行了广泛的取值测试。图 3.6 结果显示，即使 k 和 bound 在较大的区间内波动，模型的四个评估指标曲线依然保持相对平稳，并未出现剧烈的性能起伏。这表明 CSSGCL 模型对初始种子的严格规模表现出极强的不敏感性，后续的双视图图对比学习模块能够极大地弥补和纠正初始种子规模变化带来的偏差。




图 3.6 k -plex 的参数 k 和 bound 对实验结果的影响

(3) 拓扑增强边增删概率 P_{add} 与 P_{rm} 的影响

在基于 VGAE 的网络重构阶段，增边比例 P_{add} 和删边比例 P_{rm} 直接影响增强图的连通密度。对于删边比例 P_{rm} ，由于真实网络中的大部分原始连边构成了社区的基础拓扑骨架，过高的移除比例极易破坏网络原有的局部连通性，甚至导致部分边缘节点孤立；而保持一个较小的值则能精准滤除部分低相关的噪声连边。在固定 $P_{rm} = 0.05$ 即移除 5% 的低相关性边的条件下，本文测试了增边比例 P_{add} 变化对模型性能的影响。实验发现，模型对增边比例 P_{add} 较为敏感，当 P_{add} 设置为较大值如 30% 或 50% 时，模型性能能够维持在极高水平。其内在机制在于，VGAE 生成的增强图并不是对原始图数据的简单压缩，而是深度融合了节点属性的分布。较高的增边比

例能够添加更多的潜在拓扑连边，这些连接在原图中缺失但属性高度一致，从而提升增强图在结构与语义上的表达能力。所有数据集的超参数设置如表 3.7 所示




图 3.7 增边比例 P_{add} 的影响曲线

表 3.7 CSSGCL 的超参数设置

数据集	k	Bound	α	P_{add}	P_{rm}
Karate	6	2	1	0.3	0.05
Adjnoun	2	3	1	0.3	0.10
Football	4	3	1	0.3	0.05
Live Journal	3	2	1	0.5	0.05
DBLP	1	6	1	0.5	0.05
Cornell	3	5	1	0.5	0.05
Texas	3	5	1	0.3	0.05
Washington	2	3	1	0.3	0.05
Wisconsin	2	3	1	0.5	0.05
Cora	3	5	1	0.3	0.05
Citeseer	2	5	1	0.3	0.05
Pubmed	2	6	1	0.5	0.05

3.4 本章小结

本章针对传统基于种子的局部社区检测方法在存在的两大痛点，即对种子社区孤岛化的处理以及未充分利用节点的高维属性信息构建种子社区，提出了一种基于连通种子结构和图对比学习的社区检测方法 CSSGCL。

为更全面地刻画复杂网络的真实组织结构，CSSGCL 利用变分图自编码器将节点的高维属性映射至重构的拓扑空间中，捕捉节点真实的结构与属性关联，进而生

成高质量的增强图。在此基础上,模型首先提取极大 k -plex 结构挖掘高内聚的孤立种子社区;随后,通过滤除网络中的零散节点并依托原始拓扑链接,构建兼顾内部凝聚力与全局连通性的连通种子社区,保留了社区间的真实连接关系,克服了将种子视为孤立单元的局限性。最后,模型设计了双视图图对比学习机制,在统一的潜在空间中对齐孤立种子与连通种子的特征表示,实现了局部强内聚与全局连通信息的平衡,进而指导种子社区的合并。最后,借助标签传播算法将社区扩展至未分配的边缘节点,完成社区划分。

在 12 个不同领域的真实世界网络数据集上的实验表明, CSSGCL 方法在标准化互信息 (NMI)、准确率 (ACC)、F-score 和 Jaccard 等评价指标上,相比于传统的无监督方法、半监督图神经网络以及先进的图对比学习基线算法具有优势。此外,消融实验、收敛性分析以及超参数敏感性分析进一步验证了 VGAE 拓扑增强模块与双视图对比学习机制的重要性,以及模型在特征融合、拓扑去噪和训练稳定性方面的良好表现。

第4章 基于基序感知和图对比学习的社区检测方法

4.1 引言

随着复杂网络规模的扩大，传统的基于全局信息的社区检测方法难以在社区划分质量和网络规模之间取得平衡。为此，研究者们将目光转向了基于局部信息的社区检测方法。此类方法旨在围绕特定的初始核心，通过探索局部邻域的拓扑结构来识别高内聚的非重叠子结构，从而避免了对全局网络拓扑的反复计算与遍历^[66]。这种局部扩展范式在现实世界中具有极其重要的应用价值。例如在大型社交网络中，可基于已知的核心群体扩展挖掘潜在的同好社区，为个性化推荐与社群运营提供支撑^[67]；而在学术引文网络中，则能以核心文献或课题组为局部锚点，揭示新兴研究领域的结构边界与演化轨迹。

基于局部信息的社区检测方法通常遵循“种子选取—局部扩展”的研究范式。例如，基于极大团扩展的 GCE 算法^[68]或基于极大 k -plex 的扩展算法在发现紧密子图方面取得了一定成效。然而，面对真实世界中结构复杂的网络时，现有的基于局部信息的方法仍然存在两个主要问题：其一是忽略了种子社区之间的结构质量差异。现有的局部扩展策略通常对所有种子社区采取统一的扩展规则和判别标准，而未区分种子在内部连通性、结构稳定性以及拓扑重要性等方面的异质性。这种一致处理的做法容易导致低质量种子社区（如内部松散或受扰动的子图）被过度扩展，或导致高质量种子社区扩展不足，进而造成错误的社区划分。其二是未能有效兼顾网络的高阶结构与边缘节点特征表示的合理性。具体而言，现有方法大多依赖于节点间的低阶成对连接，难以反映多个节点协同交互所形成的高阶紧密性；而部分引入网络基序的高阶方法又过度依赖基序的出现频率，导致模型的关注点偏向连接密集的核心区域，这种核心偏置现象使得边缘或稀疏区域的节点在表示学习中表征不足，甚至被当作噪声忽略，最终造成社区边界刻画不完整。

为解决现有局部社区检测方法在种子扩展和拓扑特征利用方面所面临的缺陷，本章提出了一种基于基序感知和图对比学习的局部社区检测方法（Motif-aware

Graph Contrastive Learning for Community Detection, MAC)。相较于传统的局部扩展方法, MAC 方法主要从特征表示与扩展机制两个方面进行了针对性的改进:一方面,针对现有图学习模型难以兼顾高低阶拓扑语义且容易产生核心偏置的问题, MAC 在特征学习层面进行了创新设计:具体而言,为了打破低阶成对连接的表达局限,模型提取网络中的三阶与四阶基序结构构建了高阶结构超图;同时,为了避免单一依赖高阶基序导致边缘节点被忽略, MAC 设计了高低阶双通道编码架构,并通过图对比学习将低阶的局部邻接关系与高阶的多节点协同交互模式在统一的表示空间中进行对齐与融合。这种双重视角的特征融合机制使得模型在精准锚定社区高阶紧密结构的同时,有效保留了对网络全局连通性及边缘节点的感知能力。另一方面,针对现有方法因忽视种子质量差异导致的边界误判问题, MAC 在局部扩展机制上引入了种子社区质量指导策略:将传统的模块度思想推广至高阶结构层面,提出了一种基于三角基序结构的种子社区质量评价函数,赋予了模型量化并筛选高质量种子社区的能力。在此基础之上, MAC 结合基序结构增益与深层特征表示的一致性,设计了联合约束的扩展指导策略,指导种子社区向着拓扑结构更加稳健、语义特征更加一致的方向扩展。该策略有效克服了传统扩展方法中盲目扩展的弊端,提升了局部社区边界划分的准确性。

4.2 模型和方法

为解决现有基于种子的社区检测方法未能充分利用网络高阶拓扑结构以及忽略种子质量差异的问题,本章提出了一种基于基序感知和图对比学习的社区检测方法 MAC。如图 4.1 所示,该 MAC 方法的整体结构主要包含四个模块:首先是基于基序的超图构建模块,利用特定的高阶基序重塑网络拓扑;其次是高低阶双通道图对比学习模块,在统一的表示空间中协同建模低阶邻接关系与高阶交互模式;然后是特征融合模块,用于生成具备强判别性的统一节点表示;最后是基于三角基序指导的社区扩展模块,通过评估种子质量并设定约束来完成高质量的社区划分。本节将分别对这四个组成部分进行详细介绍。




图 4.1 MAC 模型框架图

4.2.1 基于基序的超图构建

给定一个无向网络图 $G = (V, E)$ ，其中 V 和 E 分别表示网络的节点集合与边集合。为了刻画节点之间的高阶协同交互关系，MAC 模型首先通过在图 G 中检测特定的高阶基序结构，来构建其对应的超图表示。

考虑到高阶基序结构在表达能力与计算复杂度之间的平衡，本文并未直接引入图 2.5 中的所有基序类型。对于三阶和四阶无向基序，诸如 M_1 、 M_3 至 M_6 等基序的边缘密度相对较低；如果全部引入，不仅无法提升社区检测效果，还会引入大量冗余的嵌套超边，导致时间复杂度呈指数级增加。另一方面， M_8 基序虽然结构最为紧密，但在真实的稀疏复杂网络中数量极少。为了充分挖掘高阶信息并保证拓扑的连通性，本文引入了边缘密度仅次于 M_8 的 M_7 基序作为稀疏性补充。因此，本文选取了包含更多连边的三个无向基序：三阶闭环基序 M_2 以及四阶高密度基序 M_7 和 M_8 ，作为构建超图的高阶基序结构单元。需要注意的是 M_7 存在两种拓扑同构形式，在实际检测时均被视为同类基序处理。




图 4.2 基序 M7 的两种形式

在基序构造阶段，模型根据 Rand-fase 算法^[69]遍历原始图 G ，统计上述三类基序在网络中的出现情况，并分别构造其对应的加权邻接矩阵，记为 A_{M2} 、 A_{M7} 和 A_{M8} ，用于表示节点在不同基序中的共现关系。为了更全面地刻画网络中的协同交互，并打破单一基序的视角局限。本文将三种高密度的基序结构 M2、M7 和 M8 进行线性聚合，得到一个统一的基序矩阵 A_m ：

$$A_m = \sum_{k \in \{M2, M7, M8\}} \omega_k A_k \quad (4.1)$$

其中， A_k 表示对应基序类型的共现矩阵，矩阵元素 $(A_k)_{ij}$ 记录了节点 v_i 与 v_j 共同参与基序 k 实例的频次。 ω_k 为调控不同基序重要性的权重系数，为简化计算，本文实验中设置 $\omega_k = 1$ 。

在此基础上，本文基于筛选后的高阶基序结构构建超图 $\mathcal{H} = (\mathcal{V}, \mathcal{E})$ ，将检测到的每一个基序实例视为一条超边，并据此构建超图结构。为了避免冗余信息的干扰，模型对所有存在包含关系的嵌套结构进行了严格的剪枝操作：如果一个基序对应的节点集合完全包含于另一个基序中，例如某个 M2 三角形完全属于某个 M8 四节点全连通团，则仅保留规模较大的结构单元。通过这种去嵌套处理，可以得到一个更加紧凑的超图表示。需要注意的是，在真实的稀疏网络中，经过严格的基序挖掘后，往往会存在部分未能参与任何 M2、M7 或 M8 高阶结构的基序孤立节点。如果直接在超图构建过程中忽略这些节点，不仅会造成原始网络局部拓扑信息的严重丢失，还会破坏整体结构连通性。为了克服这一缺陷，本文提出了一种基于原始拓扑的结构补偿策略。具体而言，针对游离于高阶基序之外的节点，模型将回溯原始图 G 的底层拓扑，依据其在原图中的真实邻接关系来构造补充的超边。通过这种依托原始

连边的降维补偿机制，模型将基序孤立节点构建到超图拓扑网络中，既保证了图的完整性，又维持了后续超图卷积计算的连通稳定性。

经过去嵌套与孤立节点补偿处理后，生成最终的超边集合 $\mathcal{E}$ 。超图的结构特征由关联矩阵 $B \in \{0,1\}^{|\mathcal{V}| \times |\mathcal{E}|}$ 定义：

$$B_{is} = \begin{cases} 1, & \text{若节点 } v_i \in e_s \\ 0, & \text{否则} \end{cases} \quad (4.2)$$

其中， v_i 代表节点 i ， e_s 代表超边 s 。该关联矩阵 B 刻画了节点与超边之间的隶属关系。在节点特征初始化方面，若数据集未提供显式的属性信息，模型将采用单位矩阵或原始图邻接矩阵作为初始节点特征输入。图 4.3 展示了使用基序构建关联矩阵的过程。

此外，本文将 M2、M7 和 M8 这类具有极高内部凝聚力的多节点协同交互结构实例，在经过合并与去除嵌套结构处理后形成的高阶子图，作为候选的初始种子社区。这种基于基序的种子定义方式，不仅确保了每一个初始种子都具备坚固的高阶拓扑结构，也为后续模型的局部社区扩展提供了高质量的基础。




图 4.3 使用基序构建关联矩阵

4.2.2 高低阶双通道图对比学习

在复杂网络中，单一视角的拓扑结构往往无法准确描绘社区的全貌。一方面，仅仅依赖成对边连接的低阶信息难以全面捕获社区的复杂拓扑特征。例如，在学术

合作网络中，单纯的两人合作连边只能反映局部的二元关系，却无法揭示由多名学者共同参与和频繁互动所构成的核心团队这种高阶紧密结构。另一方面，如果过度依赖基序结构的高阶信息，又容易使模型产生严重的核心偏置现象。例如，若强制要求节点必须参与三角基序（即至少三人互为合作者）才能被划分进社区，模型会过度聚焦于网络中连接密集的资深学者群体的核心区域，从而错误地将仅与学者有合作关系的研究员（即处于社区边缘但具有合理归属的节点）当作噪声忽略。为了克服这一固有缺陷，本文在 MAC 中设计了高低阶双通道图对比学习机制。该机制利用两个并行的图神经网络通道，分别提取网络的低阶邻接关系与高阶协同交互模式，并通过图对比学习在统一的表示空间中对齐这两种视角下的节点表示。

（1）低阶特征编码通道

低阶通道主要负责从原始的成对连接关系中提取基础的邻接拓扑语义。给定初始节点特征矩阵 X ，第 0 层的输入 $X^{(0)} = X$ ，以及原始网络的邻接矩阵 A ，本文采用两层图卷积神经网络进行编码。图卷积神经网络的信息传播公式如下：

$$X^{(l+1)} = \sigma \left(\hat{D}^{-\frac{1}{2}} \hat{A} \hat{D}^{-\frac{1}{2}} X^{(l)} \Theta^{(l)} \right) \quad (4.3)$$

其中， $\Theta^{(l)}$ 为第 l 层网络中可训练的权重参数矩阵， $\sigma(\cdot)$ 为 ReLU 激活函数。经过 L 层图卷积操作后，模型输出节点在低阶图视角下的嵌入表示，记为 $H^{(low)} = f_{\theta_l}(A, X)$ 。

（2）高阶特征编码通道

与低阶通道并行，高阶通道利用超图卷积神经网络提取网络深层的高阶协同模式。给定构建的高阶超图关联矩阵 B ，可以构建一个刻画高阶连通性的特征转移矩阵 $D_v^{-1} B W D_e^{-1} B^T$ 。该矩阵从全局结构的视角，严密描述了信息从初始节点出发，经由基序超边，再平滑扩散至其他高阶关关节点的完整传递路径。假设 $H^{(l)}$ 为第 l 层的输入节点潜在特征矩阵，其中初始输入 $H^{(0)} = X$ ，高阶通道的单层网络前向传播规则可统一表述为：

$$H^{(l+1)} = \sigma \left(D_v^{-1} B W D_e^{-1} B^T H^{(l)} \Theta^{(l)} \right) \quad (4.4)$$

其中， D_v 和 D_e 分别为表示超图节点度和超边度的对角矩阵， W 为超边权重对角矩

阵, $\hat{\Theta}^{(l)}$ 为第 l 层的可训练参数, $\sigma(\cdot)$ 为非线性激活函数。

为了在实际计算中优化矩阵乘法的复杂度, 上述高阶聚合操作在实现时可解耦为两个连续的特征投影阶段:

首先是超边投影矩阵 $E^{(l)}$ 的生成, 它代表了基序单元的整体语义编码:

$$E^{(l)} = W D_e^{-1} B^T H^{(l)} \quad (4.5)$$

随后是节点表示的加权回溯, 通过关联矩阵 B 将超边特征重新分配给所辖节点:

$$H^{(l+1)} = \sigma(D_v^{-1} B E^{(l)} \Theta^{(l)}) \quad (4.6)$$

经过该通道的处理, 最终得到节点在超图视角下的高阶基序嵌入表示, 记为 $H^{(high)} = g_{\theta_h}(B, X)$ 。

(3) 基于超边构造的图对比学习

在获得 $H^{(low)}$ 和 $H^{(high)}$ 之后, 为了在统一的表示空间中联合建模这两种层次的拓扑语义, 模型引入了基于多层感知机的共享投影头 $p(\cdot)$, 将这两种表示映射到同一个对比空间中, 分别得到 $Z^{(low)} = p(H^{(low)})$ 和 $Z^{(high)} = p(H^{(high)})$ 。

在图对比学习模块中, 正负样本对的构建直接影响了模型捕获先验拓扑知识的能力。本文充分利用了由基序构建的超图结构来指导正负样本的划分: 对于任意给定节点 v_i , 与其位于同一条超边即参与了同一个高阶基序的节点被视为具有强结构相关性, 共同构成正样本集合 $Pos(i)$; 而不属于该高阶结构的节点则被视为负样本。这种基于超边的正样本采样策略, 使得模型不仅关注直接的拓扑边连接, 还能感知多节点间的协同作用。

基于上述正负样本设置策略, 模型采用基于 InfoNCE 改进的对比学习损失函数进行优化:

$$\mathcal{L}_{cl} = -\frac{1}{n} \sum_{i=1}^n \log \frac{\sum_{j \in Pos(i)} e^{\text{sim}(Z_i^{(low)}, Z_j^{(high)})}}{\sum_{i'=1, i' \neq i}^n e^{\text{sim}(Z_i^{(low)}, Z_{i'}^{(low)})} + \sum_{j'=1}^n e^{\text{sim}(Z_i^{(low)}, Z_{j'}^{(high)})}} \quad (4.7)$$

其中, $\text{sim}(\cdot, \cdot)$ 表示两个向量之间的余弦相似度。通过最小化该对比损失, 模型能够拉近语义一致且共处同一高阶基序的正样本节点在不同视图下的表示, 同时拉远无关节点之间的距离。这一对齐机制能够弥补低阶网络与高阶超图之间的语义鸿沟, 为后续的特征融合与高质量社区扩展学习具有判别性的表示。

4.2.3 高低阶特征融合

通过上一小节的高低阶双通道图对比学习模块, 模型已经在统一的表示空间中对齐了节点的低阶邻接语义与高阶协同语义。为了在后续在社区扩展阶段提供一个兼具局部与全局视野, 且对噪声具有强鲁棒性的综合节点特征, 本模块对这两个通道的输出特征进行了深度融合。具体而言, 本方法采用平均聚合的方式, 将图卷积网络输出的低阶信息表示 $Z^{(low)}$ 与超图卷积网络输出的高阶信息表示 $Z^{(high)}$ 进行结合:

$$Z^{(out)} = \frac{1}{2} Z^{(low)} + \frac{1}{2} Z^{(high)} \quad (4.8)$$

这种直接的特征融合策略不仅计算高效, 而且能够使得最终的节点嵌入表示 $Z^{(out)}$ 同时包含原始图的拓扑连接细节和由基序诱导的高阶交互骨架。融合后的全局特征表示提升了模型的表达能力与泛化能力, 为后续衡量节点与社区之间的语义一致性提供了支撑。

4.2.4 种子社区质量评价与扩展指导

在获取了高质量的融合节点表示后, 模型的最终任务是围绕初始种子完成社区的扩展。为了消除初始候选种子概念的模糊性, 并避免孤立基序过于零散, 本节首先明确初始种子社区的构建机制: 在正式进入扩展阶段前, 依据本节设计的联合扩展评分函数, 预先对网络中挖掘出的 M2、M7 和 M8 高阶结构实例进行自适应合并, 并严格剔除存在包含关系的嵌套结构。经过这一融合与去重处理后, 保留下来的高阶紧密拓扑单元即构成了模型真正意义上的初始种子社区, 用于后续在社区扩展。随后, 与传统局部社区检测方法对所有种子采取统一扩展策略不同, 本文创新性地提出了一种基于基序指导的质量评价与联合扩展机制, 以确保高质量的初始种

子被优先利用，并指导社区向着结构稳定的方向演化。

(1) 基于三角基序的种子社区质量评价函数

模块度通常被用来衡量网络划分的质量，但其核心思想仅停留在低阶的边密度层面，即比较真实网络中的边分布与保持节点度不变的随机网络中的期望边分布。这种基于低阶拓扑的度量难以反映多节点协同交互所形成的高阶紧密性。为此，本文将模块度思想推广至高阶结构层面，提出了一种基于三角基序 M_2 的社区质量评价函数 M_Q 。

给定种子社区 C_i ，设网络中包含的三角基序集合为 D_{M_t} ，网络总边数为 $|E|$ ，社区 C_i 内部包含的三角基序数量记为 $|D_{M_t}(C_i)|$ 。在保持节点度不变的随机网络前提下，任意两个节点 u 和 v 之间存在连边的期望概率为 $p_{uv} = \frac{d_u d_v}{2|E|}$ 。三角基序是由三个节点两两相连构成的闭合结构。假设随机网络中边的生成是相互独立的，那么任意三个节点 u, v, w 共同构成一个三角基序的理论期望概率 $E_{\Delta}(u, v, w)$ ，即为这三条连边 (u, v) , (v, w) , (w, u) 同时存在的概率乘积。推导过程如下：

$$E_{\Delta}(u, v, w) = p_{uv} \cdot p_{vw} \cdot p_{wu} = \left(\frac{d_u d_v}{2|E|} \right) \left(\frac{d_v d_w}{2|E|} \right) \left(\frac{d_w d_u}{2|E|} \right) = \frac{d_u^2 d_v^2 d_w^2}{(2|E|)^3} \quad (4.9)$$

在计算整个候选社区 C_i 内期望的三角基序总数时，若直接对社区内所有节点进行三重嵌套遍历计算概率和，会产生大量无意义的冗余项，例如 $u=v$ 或 $u=v=w$ 的自环项以及重复计算项例如排列 (u, v, w) 与 (v, u, w) 实际上映射的是同一个拓扑三角形。为了消除无意义项并剔除重复计算以降低复杂度，本文在累计期望时引入了严格的节点索引序约束 $u < v < w$ 。结合真实网络中种子社区 C_i 内部实际包含的三角基序数量，本文定义了一个新的高阶基序模块度函数：

$$M_Q(C_i) = \frac{1}{|D_{M_t}|} \left[|D_{M_t}(C_i)| - \sum_{\{u < v < w\} \in C_i} \frac{d_u^2 d_v^2 d_w^2}{(2|E|)^3} \right] \quad (4.10)$$

其中，方括号内第一项 $|D_{M_t}(C_i)|$ 刻画了当前种子社区内实际拥有的高阶紧密连接数

量，第二项 $\sum \frac{d_u^2 d_v^2 d_w^2}{(2|E|)^3}$ 则是节点度相同的随机网络下，这些节点形成三角基序的理论连接期望。将两者的差值除以网络总基序数 $|D_{Mt}|$ 进行归一化，即可得到种子社区的高阶质量得分。当 $M_Q(C_i)$ 取值较大时，表明该候选种子社区 C_i 内部包含了显著多于随机网络的高阶结构，具有更强的凝聚性与抗噪稳定性；反之，则说明该种子质量较差。通过计算所有候选种子的 M_Q 值并进行排序，算法能够筛选并优先扩展高质量的种子社区。此外，将所有种子社区的 M_Q 值进行求和，即可得到网络的质量得分。

(2) 基于基序的结构约束与表示一致性扩展

在确定了高质量的种子社区 C 后，对于其邻居节点集合中的任意候选节点 $v \in \mathcal{N}(C)$ ，本文设计了一种联合结构增益与特征相似度的扩展评分机制。

针对结构约束方面，本文根据候选节点 v 加入社区后与原社区节点形成的三角基序关系，将其划分为三种类型：

- **内部基序** (M_{triple})：三角形中的三个节点均属于更新后的社区。它反映了社区核心的高阶内聚力，是社区稳定性的直接体现。
- **部分内部基序** (M_{double})：三角形中有两个节点属于社区，一个节点在外部。这类基序具有极强的扩展指示意义，暗示着潜在的社区扩展边界。
- **边缘基序** (M_{one})：三角形中仅有一个节点属于社区。这类结构往往对应于不同社区间的交叉噪声连接，对当前社区的扩展有消极作用。

基于上述分类，本文定义了一个基于基序的社区扩展评分函数 $S_{motif}(v, c)$ ，如公式(4.11)所示，用于衡量当前社区结构的高阶连通性程度。

$$S_{motif}(v, c) = \begin{cases} 0, & M_{triple} = M_{double} = M_{one} = 0; \\ e^{\frac{M_{triple} + \alpha M_{double} - \beta M_{one}}{M_{triple} + M_{double} + M_{one}}}, & otherwise. \end{cases} \quad (4.11)$$

其中，参数 α 用于控制 M_{double} 对社区扩展的正向贡献，参数 β 用于调节 M_{one} 所带来

的负向影响，二者均用于平衡不同基序类型在扩展决策中的作用。通过适当约束参数取值，评分函数 $S_{\text{motif}}(v, c)$ 被归一化到区间 $[0, 1]$ 。 $S_{\text{motif}}(v, c)$ 的取值越大，表明社区内部包含的高阶紧密结构越多，社区结构越稳定。模型可以计算节点 v 加入后为社区带来的结构质量评分增益 $\Delta S_{\text{motif}}(v, C)$ 来指导社区的扩展。该机制优先鼓励那些能够闭合生成更多 M_{triple} 和 M_{double} 同时尽量避免产生 M_{one} 的节点加入社区。因此，在社区扩展过程中，本文采用一种基于评分增益的策略：对于候选节点 $v \in \mathcal{N}(C)$ ，其中 $\mathcal{N}(C)$ 表示社区 C 的邻居节点集合，将其加入社区后得到新的社区 $C' = C \cup v$ ，并计算对应的社区质量评分 $S_{\text{motif}}(v, C')$ 。若加入节点 v 能够使评分函数增大，则认为该节点符合社区扩展方向，并被纳入社区。

$$\Delta S_{\text{motif}}(v, c) = S'_{\text{motif}}(v, c) - S_{\text{motif}}(v, c) = e^{\frac{M'_{\text{triple}} + \alpha M'_{\text{double}} - \beta M'_{\text{one}}}{M'_{\text{triple}} + M'_{\text{double}} + M'_{\text{one}}}} - S_{\text{motif}}(v, c) \quad (4.12)$$

为便于计算，设 M'_{triple} 、 M'_{double} 和 M'_{one} 分别表示扩展后社区 C' 中三类基序的数量，其具体计算方式基于节点 v 加入社区后所参与的不同类型三角基序数量。记 $m_{\text{triple}}(v)$ 、 $m_{\text{middle}}(v)$ 和 $m_{\text{one}}(v)$ 分别表示节点 v 在加入社区后新增的三类基序数目，公式如下：

$$M'_{\text{triple}} = M_{\text{triple}} + m_{\text{triple}}(v) \quad (4.13)$$

$$M'_{\text{double}} = M_{\text{double}} + m_{\text{double}}(v) - m_{\text{triple}}(v) \quad (4.14)$$

$$M'_{\text{one}} = M_{\text{one}} + m_{\text{one}}(v) - m_{\text{double}}(v) \quad (4.15)$$

在表示一致性约束方面。如果仅依赖网络拓扑连接关系进行扩展，模型容易被社区交界处的基序结构所误导，将特征不相关的区域错误合并，造成社区的过度扩展。因此，模型利用特征融合模块输出的表示 $Z^{(\text{out})}$ ，节点 u 的特征向量为 h_u ，计算社区中心表示 $h_c = \frac{1}{|C|} \sum_{u \in C} h_u$ 。候选节点 v 与社区 C 的语义特征一致性评分 $S_{\text{emb}}(v, C)$

可通过计算 h_v 与 h_c 之间的余弦相似度获得。

最终，我们定义联合扩展评分函数如下：

$$S(v, C) = \lambda \cdot S_{\text{motif}}(v, C) + (1 - \lambda) \cdot S_{\text{emb}}(v, C) \quad (4.16)$$

其中， $\lambda \in [0, 1]$ 为平衡超参数，用于调节高阶结构约束与深层语义特征在扩展决策中的权重。在迭代扩展过程中，算法优先吸纳联合评分 $S(v, C)$ 增大的候选节点加入社区，并根据基序模块度选择加入的社区，直至评分不再提升。这一设计不仅保证了社区在拓扑结构上的高阶紧凑性，同时确保了成员在潜在语义空间中的高度一致性。

4.3 实验验证与结果分析

为了全面评估本章提出的基于基序感知和图对比学习的社区检测方法的有效性，本节在多个不同规模与特征的真实世界网络数据集上进行了广泛的实验验证，并与当前多项主流的图表示学习及高阶社区检测基线算法进行了对比。

4.3.1 数据集与评价指标

为了从多维度客观验证 MAC 方法的性能，本次实验选取了 7 个在复杂网络社区检测领域被广泛使用的真实世界数据集。这些数据集涵盖了社交互动、引文关系以及词汇共现等多种真实场景，其基本统计特征包括节点数、边数、真实社区数及属性维度如表 4.1 所示。本节的实验不仅沿用了第三章中已经介绍过的图数据集 Washington、Cora 和 Citeseer，还额外引入了四个新的社交网络数据集：Sinanet 数据集是从新浪微博网站中提取的用户关系数据网络，每个节点代表着活跃于财经、体育以及文艺等不同领域的博客用户，边表示用户之间关注与被关注者的关系，用户的属性由 LDA 模型提取生成。Twitch、LastFM 和 Deezer 均来自斯坦福网络分析平台数据集^[70]。其中，Twitch 网络来自流媒体服务 Twitch 的游戏玩家社交网络，每个节点表示一个游戏玩家，若游戏玩家间存在好友或交易关系，就生成一条边，节点特征基于用户玩过和喜欢的游戏、地理位置以及直播习惯提取。LastFM 网络是一个音乐社交网络，节点代表来自亚洲国家的 LastFM 用户，边代表用户之间的相

互关注关系，节点特征基于用户喜欢的艺术家提取。Deezer 是全球第二大的独立音乐流媒体平台，节点代表用户，边代表用户之间的相互关注关系，其网络构建方式与 LastFM 类似。

表 4.1 数据集介绍

数据集	节点数	边数	社区数	属性数
Washington	230	446	5	1703
Cora	2708	5429	7	1433
Citeseer	3312	4732	6	3703
Sinanet	3490	30282	10	10
Twitch	4648	59382	2	19391
LastFM	7624	27806	18	395378
Deezer	28281	92752	2	33891

图 4.4 展示了在 Washington、Cora 和 Citeseer 等 7 个数据集中，不同类型的基序数量与网络边数的比例分布情况。根据图可得知，尽管基序的相对密度在不同规模和属性的数据集中存在一定的波动差异，但 M1、M3 和 M5 等低连通性的开放基序在所有数据集中均普遍占据了极高的比例，尤其是在 Sinanet 数据集中，M3 和 M5 的比例远超其他基序。如果模型利用这些低连通性、呈链状或星状散布的基序来构建超边，将会生成很多不合理的冗余连接，从而产生拓扑误导信息。因此，本文在构建高阶结构超图时，选择专门提取 M2、M7 以及 M8 等高内聚的高阶基序。虽然这些闭合基序在网络中出现的比例相对较低，但它们具备极强的结构稳定性与抗噪能力，能够确保超图精准锚定复杂网络中真实的深层社区核心。




图 4.4 不同基序类型占边数的比例

不同数据集中的基序分布比例虽存在差异，但普遍存在大量的低阶和高阶结构，这为验证模型的高低阶特征提取能力提供了良好的数据基础。为了准确衡量网络划分的质量，本章实验采用了以下评估指标：

标准化互信息与 F-score 相似度已在 3.3.1 中详细说明，本节不再赘述。

基序模块度 M_Q ：这是本文专门针对高阶社区结构引入的重要评价指标。传统的模块度 Q 仅度量低阶成对边结构的紧密性，而 M_Q 函数则将划分社区内的实际三角基序数量与保持度分布不变的随机重连网络中的期望三角基序数量进行对比。

M_Q 值越高，表明社区在高阶协同结构上的内部凝聚力越强、划分结构越合理。

4.3.2 实验设置

为了确保实验对比的公平性与可重复性，MAC 模型及其变体均在统一的软硬件环境下进行训练。硬件平台配置为搭载 Intel® Xeon® CPU 与 NVIDIA RTX 4090 GPU 的深度学习工作站。软件环境采用 Python 3.7 以及 PyTorch 1.7 框架。在模型超参数配置方面，MAC 模型统一使用 Adam 优化器进行网络参数更新。经过多次调参验证，本文发现学习率的微小变化对大部分数据集影响较小，而隐藏层维度的影响显著。当隐藏层维度达到 128 维后，性能提升趋于平缓。因此，双通道图神经网络 GCN 与 HGNN 的层数均设置为 2 层，隐藏层维度统一设定为 128 维，初始学习率设定为 5×10^{-3} 。

4.3.3 对比方法

为了突出本文提出的 MAC 模型在融合高低阶特征以及局部社区扩展机制方面的有效性,实验选取了包含传统图嵌入、图神经网络以及高阶基序挖掘等不同技术路线的 7 种基线方法进行对比。这些对比方法主要分为以下两类:

(1) 基础图表示学习方法。这类方法主要依赖网络中低阶的边连接信息进行节点特征编码:

Node2vec 模型^[62]: 一种基于随机游走的经典图嵌入模型。该方法基于偏置随机游走机制,通过在图中采样节点序列并结合 Skip-Gram 模型,学习并捕捉网络局部同质性与结构等价性的低维节点向量表示。

GCN 模型^[34]: 标准的图卷积神经网络。该模型通过在傅里叶域近似谱图卷积,实现了节点自身特征与其一阶局部邻域拓扑信息的聚合与特征学习。

GAT 模型^[71]: 引入注意力机制的图卷积神经网络。该模型允许网络在聚合邻域信息时,自适应地为不同的邻居节点分配不同的重要性权重,从而提升了低阶特征提取的灵活性。

(2) 基于高阶基序与图学习的方法。这类方法致力于突破低阶边连接限制,利用网络基序或超图等高阶结构来指导图表示学习与社区检测:

MGNN 模型^[72]: 该模型提出了一种结合基序冗余最小化的高阶结构图神经网络框架,利用由多节点构成的基序模式来增强图表示的表达能力。

MWLP 模型^[73]: 该模型通过整合网络的低阶边拓扑与三角基序结构,构建了一个综合的加权网络,随后在此加权图上应用标签传播算法来完成社区检测。

MotifCC 模型^[37]: 该模型探索了高阶拓扑的对比学习策略,但其仅使用三角基序构建的种子图进行对比学习,在扩展阶段仅通过标签传播算法实现社区划分,而未考虑种子质量之间的差异。

HGNN 模型^[75]: 经典的超图神经网络。该模型直接利用构建的超图关联矩阵进行超图卷积运算以学习节点的高阶表示,完全摒弃了原图中的低阶邻接信息。

4.3.4 主要实验结果

为了验证所提出的 MAC 模型的有效性, 本节在 Washington、Cora 和 Citeseer 等 7 个真实世界属性网络数据集上, 将其与 Node2Vec、GCN 以及 MGNN 等 7 种基线算法进行了全面的性能评估。各算法在标准化互信息、F-Score 相似度、传统模块度以及高阶基序模块度四个评价指标上的实验结果分别如表 4.2 至表 4.5 所示。基于实验结果, 我们可以提炼出以下几个关键结论:

(1) 从全局对比结果来看, MAC 在各类不同规模和拓扑特征的数据集上均表现出了有效的社区检测能力。尤其是在大规模流媒体社交网络如 Deezer 和 LastFM 上, MAC 方法在各项指标上均排在前列。在 Cora 数据集上, MAC 取得了最高的 NMI; 在 Twitch、LastFM 和 Deezer 数据集上, MAC 的 F-Score 分别达到了 0.467、0.534 和 0.536, 展现出较好的聚类性能。这验证了其在处理富含高维属性与复杂拓扑的网络时的更好性能。尽管在 Citeseer 等极少数数据集的个别指标上, MAC 受到网络稀疏性的影响, 社区划分效果略低于特定的基序方法, 但其综合表现占据主导地位。

表 4.2 经典网络上 NMI 的实验结果对比

方法	Washington	Cora	Citeseer	Sinanet	Twitch	LastFM	Deezer
Node2Vec	0.143	0.448	0.249	0.224	0.195	0.268	0.291
GCN	0.488	0.545	0.434	0.415	0.298	0.452	0.486
GAT	0.536	0.551	0.447	0.428	0.314	0.467	0.495
MGNN	0.552	0.564	0.476	0.453	0.346	0.491	0.518
MWLP	0.421	0.415	0.238	0.316	0.213	0.342	0.375
MotifCC	0.540	0.536	0.552	0.435	0.321	0.475	0.502
HGNN	0.531	0.505	0.478	0.442	0.335	0.483	0.506
MAC	0.543	0.592	0.503	0.423	0.354	0.482	0.546

(2) 与 Node2Vec、GCN 以及 GAT 等仅依赖低阶成对连接的图表示学习方法

相比,MAC 模型在所有数据集上均实现了性能提升。例如在节点特征丰富的 Sinanet 和 Twitch 数据集中,传统的 GCN 和 GAT 难以充分捕捉用户之间复杂的群体互动效应;而 MAC 模型通过提取高阶基序构建超图,将多节点间的协同交互关系注入到模型的底层表示中,具体而言,MAC 在 Sinanet 上的 F-Score 达到 0.506,相比 GCN 的 0.431 提升了约 17.4%,这一提升表明了高阶超图卷积模块能够精准捕捉到低阶邻接矩阵所无法反映的社区骨架,从而为节点提供更具判别力的特征。

(3) 在与 MGNN、MWLP、MotifCC 以及 HGNN 等专门针对高阶结构设计的社区检测算法的比较中,MAC 模型同样表现出极强的竞争力。现有的大多数高阶方法如 MGNN 或仅利用超图卷积的 HGNN 往往过度依赖基序的出现频率,导致模型在优化时偏向于网络中连接密集的核心区域,难以兼顾边缘节点划分的合理性。MAC 模型通过设计高低阶双通道对比学习架构,在提取超图高阶特征的同时,利用图卷积网络保留了原图的低阶邻接拓扑。这种协同建模机制使得 MAC 既能利用高阶结构锚定社区的核心凝聚块,又能通过低阶关系合理划分边缘节点,有效避免了社区边界的丢失与误判。

表 4.3 经典网络上 F-Score 的实验结果对比

方法	Washington	Cora	Citeseer	Sinanet	Twitch	LastFM	Deezer
Node2Vec	0.104	0.427	0.209	0.352	0.284	0.381	0.412
GCN	0.425	0.468	0.376	0.431	0.386	0.454	0.478
GAT	0.492	0.479	0.381	0.445	0.398	0.467	0.491
MGNN	0.541	0.528	0.412	0.482	0.435	0.503	0.526
MWLP	0.423	0.395	0.294	0.378	0.312	0.405	0.434
MotifCC	0.512	0.495	0.395	0.461	0.412	0.482	0.505
HGNN	0.508	0.482	0.389	0.455	0.421	0.478	0.512
MAC	0.475	0.517	0.436	0.506	0.467	0.534	0.536

(4) 传统的模块度 Q 仅关注低阶边密度的增加,而高阶基序模块度 M_Q 函数则严格评估了划分结果在高阶模式上的结构一致性。观察表 4.5 可以发现,MAC 模

型在 7 个数据集中上均取得了最好的高阶模块度得分。其根本原因在于 MAC 设计的联合约束扩展策略：在局部种子扩展阶段，MAC 优先吸纳那些能够产生密集高阶基序增益的节点，并结合特征语义的一致性进行双重约束，从而有效阻止了外围噪声节点的并入。这种机制保证了局部社区向着结构更紧密、高阶连通性更强的方向扩展，最终输出了内部高内聚的高质量社区划分结果。

(5) 在衡量社区拓扑紧密性的两类模块度指标高阶 M_Q 与传统 Q 上，MAC 模型展现出了领先的优势，验证了其能有效兼顾高低阶结构。如表 4.4 所示，在衡量低阶边密度的传统模块度 Q 指标上，MAC 模型同样实现了领先。高阶方法 MotifCC 和 HGNN 往往为了追求高阶基序的聚集而牺牲了网络底层的连通基础；而 MAC 模型通过高低阶双通道架构，在利用超图锚定核心的同时，通过图卷积通道精准保留并对齐了原图的低阶邻接拓扑。这种双通道的机制，使得 MAC 划分出的社区不仅内部高阶结构紧密连接，同时也保持了宏观边级别上的高内聚性，实现了社区划分质量的提升。

表 4.4 经典网络上模块度 Q 的实验结果对比

方法	Washington	Cora	Citeseer	Sinanet	Twitch	LastFM	Deezer
Node2Vec	0.354	0.421	0.384	0.405	0.312	0.445	0.452
GCN	0.451	0.531	0.468	0.502	0.384	0.521	0.535
GAT	0.463	0.545	0.472	0.511	0.395	0.534	0.542
MGNN	0.495	0.578	0.512	0.542	0.428	0.567	0.575
MWLP	0.412	0.485	0.402	0.451	0.345	0.472	0.481
MotifCC	0.482	0.561	0.504	0.528	0.415	0.552	0.560
HGNN	0.470	0.553	0.481	0.515	0.402	0.540	0.548
MAC	0.568	0.529	0.415	0.566	0.452	0.585	0.593

表 4.5 经典网络上 M_Q 的实验结果对比

方法	Washington	Cora	Citeseer	Sinonet	Twitch	LastFM	Deezer
Node2Vec	0.452	0.523	0.532	0.481	0.445	0.462	0.455
GCN	0.554	0.651	0.635	0.592	0.550	0.565	0.571
GAT	0.568	0.668	0.652	0.615	0.572	0.588	0.595
MGNN	0.621	0.795	0.701	0.664	0.631	0.645	0.652
MWLP	0.635	0.731	0.715	0.678	0.645	0.661	0.668
MotifCC	0.648	0.745	0.728	0.691	0.662	0.674	0.685
HGNN	0.652	0.752	0.735	0.705	0.675	0.682	0.691
MAC	0.721	0.729	0.775	0.754	0.723	0.734	0.746

4.3.5 消融实验

为了深入验证 MAC 框架中各个核心模块对最终社区检测性能的具体贡献，本节在统一的实验设置下进行了消融实验与分析。具体而言，本文设计了以下三种基线变体：

- MAC-L（移除低阶通道）：以基序矩阵作为输入，仅使用超图卷积来学习节点的高阶表示，没有使用网络中原始的成对连接信息。
- MAC-H（替换高阶超图架构）：以原始图的邻接矩阵和基序矩阵输入并行的 GCN 中，将特征加权求和后得到网络嵌入表示，仅使用图卷积来学习节点表示。
- MAC- M_Q （替换扩展指导策略）：在种子扩展阶段未使用本文设计的扩展指导函数，而是退化为使用经典的标签传播算法进行社区划分。

通过将完整的 MAC 模型与上述变体进行对比，可以得出以下结论：

（1）如表 4.6 所示，当高阶通道退化为普通图卷积 MAC-H 时，模型性能出现下滑。例如在 Cora 数据集上，MAC-H 的 M_Q 值仅为 0.452。这表明，传统的 GCN 即便输入了基序矩阵，也无法在底层捕获多节点如三角基序的联合协同效应，验证了采用超图架构处理高阶特征的必要性。

表 4.6 消融实验结果

Moethod	Cora			Citeseer			Sinanet		
	NMI	F-Score	M_Q	NMI	F-Score	M_Q	NMI	F-Score	M_Q
MAC-H	0.526	0.445	0.452	0.431	0.365	0.354	0.359	0.426	0.347
MAC-L	0.550	0.495	0.635	0.468	0.398	0.468	0.384	0.474	0.564
MAC- M_Q	0.565	0.502	0.641	0.476	0.413	0.497	0.412	0.489	0.557
MAC	0.592	0.517	0.729	0.503	0.436	0.775	0.423	0.506	0.754

(2) 完全丢弃低阶邻接信息即变体 MAC-L 同样会导致性能降低, 例如在 Citeseer 数据集上, 其 F-Score 从完整模型的 0.436 降至 0.398。其原因在于, 仅依赖超图卷积虽能锚定高内聚核心, 但会忽略未形成高阶闭环的外围节点。失去了低阶连边的兜底, 这些边缘节点极易被错分。这验证了本文高阶锚定核心, 低阶弥补边缘双通道机制在维持社区边界上的有效性。

(3) 当模型退化为扩展阶段使用经典标签传播算法即 MAC- M_Q 后, 各项指标均有回落, 但相比于移除低阶通道和替换高阶架构的变体, 指标下降幅度最小。传统的标签传播容易越过社区边界造成社区合并, 而本文设计的扩展指导函数通过考量基序增益与特征一致性, 有效约束了扩展路径, 保障了局部社区向着更紧密的方向成型。

4.3.6 超参数分析

为了验证 MAC 模型在不同参数配置下的性能影响, 并探究核心超参数对社区检测性能的具体影响, 本节以 Cora, Citeseer 和 Sinanet 数据集为例, 对模型中的几个关键超参数进行了分析。评价指标统一采用标准化互信息 (NMI) 和 F-score。此外, 为保证实验变量控制的严谨性, 在进行超参数的影响分析时, 模型其余基础参数均固定为经过前期实验验证的最优取值, 即实验中统一设置参数 $\alpha = 0.5$, 参数 $\beta = 2$ 。

(1) 扩展权重参数的影响。参数 λ 用于在局部社区扩展阶段调节高阶结构约束与深层特征一致性之间的权重占比。如图 4.5 所示，当 $\lambda=0$ 时或 $\lambda=1$ 时，模型的划分性能均处于较低水平。这充分说明了单一视角的局限性，仅依赖节点特征容易吸纳拓扑上毫无关联的节点，而仅依赖网络拓扑则极易被少数跨越社区边界的连边所误导，引发社区的过度扩展。随着 λ 取值逐渐向中间靠拢如在 Cora 数据集上 $\lambda \approx 0.6$ 时，模型性能达到峰值。这一倒 U 型趋势验证了 MAC 模型设计的结构与语义联合扩展策略的合理性。




图 4.5 超参数 λ 对实验结果的影响

(2) 图卷积层数的影响。图卷积层数 L 决定了模型捕获网络高阶及低阶邻居信息的感受野大小。如图 4.6 所示，当 $L=2$ 时，模型性能达到最优。当 $L \geq 3$ 时，模型的 NMI 得分开始出现持续的衰减。这是因为过深的网络层数引发了图神经网络中的过平滑问题，导致不同社区节点的特征表示趋于同质化，丧失了边界判别能力。因此，本文在主实验中统一将网络层数设置为 2。




图 4.6 图神经网络层数对实验结果的影响

4.3.7 社区划分可视化




图 4.7 MAC 与对比方法在 Cora 数据集上的二维可视化

本节以 Cora 数据集为例，利用 t-SNE 降维技术对节点在各算法下的最终嵌入表示进行了二维空间可视化。可视化结果如图 4.7 所示，其中不同颜色的散点代表节点所属的不同社区标签。通过观察各类颜色节点在二维空间的排列情况与聚集程度，可以直观地评估不同算法社区检测质量的优劣。

具体而言，在图 4.7 (a) Node2vec 和 (e) MWLP 的可视化结果中，绝大多数节点高度混杂地聚集在一个巨大的核心区域内，不同颜色的节点相互交织，几乎无法辨识出明确的社区界限。图 4.7 (b) GCN 和 (c) GAT 虽然呈现出了一定的向外发散和聚类趋势，但在中心区域的边界依然模糊，这表明仅依赖低阶成对连边的算法难以有效解耦复杂的拓扑结构。在图 4.7 (d) MGNN 和 (g) HGNN 中，节点聚集在部分核心区域构成条带状和团状，而边缘节点未能形成紧凑的社区形态，这一现象直观地反映出这类依赖高阶结构的算法因过度聚焦核心区域所引发的核心偏置问题。在图 4.7 (f) MotifCC 中，得益于高阶基序的引入，网络呈现出了一定的社区结构，能够观察到分离的区块，但社区边界依然不够清晰。相比之下，如图 4.7 (h) 所示，本文提出的 MAC 模型的社区划分边界最为明显。在 MAC 的可视化结果中，各社区之间的间隔清晰可见，呈现出类内紧凑，类间分离的形态；同时，与 MGNN 和 MotifCC 相比，MAC 划分出社区边界更加清晰，没有出现松散的游离节

点。这一可视化结果验证了 MAC 模型通过高低阶双通道图对比学习有效融合了多层次拓扑语义，不仅能够精准锚定社区核心，还能够克服了核心偏置缺陷，从而获得了高质量的社区划分结果。

4.3.8 复杂度分析

为了全面评估不同算法在实际应用中的计算效率，本节对对比模型以及本文提出的 MAC 模型的时间复杂度进行了理论分析。为方便表述，假设网络中节点数量为 n ，边数量为 m ， v 为网络的平均度。在神经网络架构中，设输入特征维度为 F ，隐藏层维度为 d ，输出层维度或社区数量为 c ，模型层数为 L 。

- **Node2vec:** 假设在随机游走阶段，网络中的 n 个节点各进行了 R 次长度为 l 的随机游走。在随后的 Skip-Gram 模型训练中，假设窗口大小为 w ，嵌入维度为 c ，则该算法整体的时间复杂度为 $O(nRlwc)$ 。
- **GCN, GAT:** 相比于基础的多层感知机，图神经网络在输入、隐藏层和输出层均增加了基于网络拓扑的聚合操作，隐藏层的聚合复杂度为 $O(mdL + nd^2L)$ 。假设网络稀疏且特征映射占主导，这两种基础图神经网络的前向传播总复杂度可统一近似并化简为 $O(md(F + dL + c))$ 。
- **MGNN:** 该方法需要计算网络中的高阶基序，不同类型基序的搜索代价差异较大。对于部分复杂的结构模式，其计算复杂度最高是 $O(n^3)$ 。加上后续图网络的训练，其整体总复杂度为 $O(n^3 + md(F + dL + c))$ ，在大型网络中极易遇到计算瓶颈。
- **MWLP:** 该方法整合了高低阶结构来构建加权网络。在前期的数据预处理中，寻找特定的高阶基序的复杂度约为 $O(mv^2)$ 。随后使用的标签传播算法的复杂度与边数线性相关。因此，其整体复杂度主要受限于前期的基序挖掘阶段。
- **MotifCC:** 该方法仅使用三角基序生成种子进行图对比学习。其寻找三角基序的复杂度同样为 $O(mv^2)$ 。在随后的图对比学习中，由于未构建稀疏超图，而

是直接计算对比损失,其损失计算部分的复杂度通常与节点数的平方 $O(n^2)$ 或批次大小成正比。

- **HGNN**: 若直接使用传统的超图神经网络学习高阶表示,假设网络中提取的初始基序总数为 p 。在不进行冗余剔除的情况下将这 p 个结构全部转化为超边,其超图前向传播的总复杂度将达到 $O(mv^2 + d(m + p)(F + dL + c))$, 包含大量冗余计算。
- **MAC**: 该方法的复杂度主要由数据处理与双通道前向传播两部分构成。(1) 在基序挖掘阶段,寻找三阶与四阶基序的复杂度约为 $O(mv^2)$; 在随后的嵌套冗余剔除过程中,遍历并移除关联低阶超边的复杂度为 $O(p)$ 。因此该阶段复杂度为 $O(mv^2 + p)$ 。(2) 在双通道前向传播阶段,假设经过冗余剔除后,超图中最终保留的紧凑超边数量降为 q 。此时,低阶成对图卷积的复杂度为 $O(md(F + dL + c))$, 高阶超图卷积的复杂度为 $O(qd(F + dL + c))$ 。两者并行结合的总前向传播复杂度为 $O((m + q)d(F + dL + c))$ 。因此,MAC 模型的整体时间复杂度可近似表示为: $O(mv^2 + p + (m + q)d(F + dL + c))$ 。

综上所述,尽管本文提出的 MAC 模型引入了高阶基序的挖掘与处理过程,但由于在构建超图时设计了冗余信息剔除机制,缩减了最终参与运算的超边数量 q 。使得 MAC 模型避免了传统超图方法中庞大的计算开销,整体计算复杂度能够与主流的高阶图深度学习方法保持在同一量级,同时在不增加计算开销的前提下,提升了社区划分的准确度。

4.4 本章小结

本章针对传统的局部社区检测方法在扩展过程中忽略种子社区质量差异,以及传统图神经网络只能提取低阶成对拓扑而缺乏高阶协同信息捕获能力的两大痛点,提出了一种基于基序感知和图对比学习的社区检测方法。

本章详细阐述了 MAC 模型的四个部分。首先,为了更好地挖掘图结构中隐藏的高阶协同关系,模型提取了三阶和四阶基序结构并删除嵌套冗余,构建了高阶超图结构。其次,为了在保留低阶特征的同时融合高阶语义,设计了包含 GCN 和 HGNN 的高低阶双通道并行编码框架,并通过图对比学习在统一的潜在空间中实现了多层次表示的对齐与融合。此外,本文将模块度思想推广至高阶层面,提出了一种全新的基于三角基序的社区质量评价指标,用以量化种子社区内部的高阶连接强度。最后,设计了基于基序指导的联合扩展策略,在扩展过程中优先吸纳能形成闭合高阶基序的节点,指导社区向拓扑结构更加一致的方向稳健扩张。

在7个真实世界网络数据集上的实验结果验证了该模型在社区检测任务中的有效性。MAC 模型在 NMI、F-score 以及高阶基序模块度 M_Q 等指标上相较于传统的低阶图表示学习方法与现有的高阶社区检测基线算法具有优势。消融实验、超参数分析以及可视化进一步验证了本文提出的超图构建、高低阶双通道融合机制以及联合扩展策略在提高社区划分质量方面的重要性。

第5章 基于掩码与互信息的社区检测模型可解释性分析

5.1 引言

近年来,图神经网络与图对比学习技术在复杂网络社区检测领域取得了飞速进展。正如本文第 4 章所阐述,基于基序感知和图对比学习的社区检测方法通过深度融合高低阶拓扑语义并实施差异化的种子扩展策略,能够提升社区划分的准确性。然而,深度学习模型复杂的非线性数据变换机制不可避免地带来了黑盒属性,导致其决策过程缺乏透明度。在极其依赖决策可信度的真实场景如精准医疗、学术演化分析与关键基建网络中,仅凭高精度的划分结果已难以满足实际需求;研究者们迫切需要了解模型在进行社区边界划分时,究竟依赖了网络中的哪些关键结构与核心节点。因此,揭示模型在社区划分过程中关注的关键结构和节点信息,提高 GNN 模型在社区检测任务中的透明度和可信度,具有重要意义。

为了分析 MAC 模型中基序的重要性,本章引入了一种将掩码机制与互信息相结合的可解释性分析方法。该方法的核心思想是在原始图结构的基础上引入可学习的掩码矩阵,对节点与拓扑边进行掩码,从而过滤掉对社区结构形成贡献较低的冗余信息。在此基础上,通过不断调整掩码,使得掩码处理后生成的网络视图与原始无掩码网络模型的划分结果在标准化互信息这一指标上实现最大化或最小化,进而推导出对决策起决定性作用的核心网络成分。

基于上述理论,本章将围绕 MAC 模型的两大核心创新机制展开可解释性分析。首先,针对模型的高阶基序结构,本文将通过构建高阶超图掩码进行拓扑贡献度分析,揭示高阶基序的协同交互在形成社区边界时的重要性。其次,针对模型的局部种子扩展机制,本文将利用最小化互信息反馈策略,对模型筛选出的高质量种子社区进行扰动分析,验证三角基序结构在局部社区成型过程中的重要性。通过量化与可视化的直观讨论,本章旨在验证 MAC 模型设计的合理性。

5.2 基于掩码与互信息的社区检测模型可解释性分析

5.2.1 基于掩码保留机制的高阶基序贡献分析

在本文第 4 章提出的 MAC 模型中，高阶基序的引入是为了打破传统无监督方法过度依赖底层成对连接的局限，从而精准捕获节点间的复杂协同交互。然而，在最终形成的非重叠社区结构中，哪些高阶结构发挥了决定性的作用仍未确定。为了解答这一问题，本节在传统图掩码机制的基础上进行扩展，提出了一种基于掩码保留机制的高阶基序结构贡献分析方法，旨在揭示模型在社区划分过程中的关键拓扑结构。

为了挖掘网络中对社区划分具有决定性作用的拓扑信息，本节重点关注由三阶或四阶基序构建的高阶超图关联矩阵。设原始网络的高阶超图关联矩阵为 $B \in \mathbb{R}^{N \times E_{\text{hyper}}}$ ，其中 N 为节点数， E_{hyper} 为超边数。本文定义高阶掩码矩阵 M_{high} ，通过哈达玛积逐元素相乘对其节点与边进行调制，得到掩码处理后的高阶输入视图：

$$B_{\text{masked}} = M_{\text{high}} \odot B \quad (5.1)$$

在初始状态下， M_{high} 被初始化为全 1 矩阵，即完整保留所有的高阶基序交互。在后续的优化过程中，掩码矩阵中对应元素的值会被逐渐压缩至 0 到 1 之间。掩码值越接近 0，表示该拓扑连接对局部社区的成型贡献越低，其信息将被模型过滤掉。

将经过掩码处理的视图 B_{masked} 重新输入到训练好的 MAC 模型中，即可得到新的掩码社区划分结果 C_{masked} 。为了量化掩码操作对划分结果的影响，本节采用标准化互信息（Normalized Mutual Information, NMI）作为度量指标。设模型在无掩码状态下输出的原始最优社区划分为 C_{orig} ，则两者的 NMI 计算公式如下：

$$\text{NMI}(C_{\text{orig}}, C_{\text{masked}}) = \frac{2 \cdot I(C_{\text{orig}}, C_{\text{masked}})}{H(C_{\text{orig}}) + H(C_{\text{masked}})} \quad (5.2)$$

其中， $I(C_{\text{orig}}, C_{\text{masked}})$ 表示两种划分结果之间的互信息， $H(\cdot)$ 表示划分结果的信息熵。

为了挖掘出最核心的拓扑结构，本文固定 MAC 模型的各项网络参数，通过反

向传播仅对掩码矩阵 M_{high} 进行梯度更新。优化的目标是在最大化 $NMI(C_{orig}, C_{masked})$ 的同时, 引入 L_1 正则化约束以迫使掩码矩阵尽可能稀疏。这一最大化互信息反馈策略的意义在于: 用数量最少的高阶基序连接, 还原出与原始模型最接近的社区划分。

为了定量分析高阶拓扑结构对社区划分的决定性作用, 本节在 Football、Cora 与 Citeseer 三个真实数据集上, 统计了不同高阶基序保留比例与模型划分 NMI 值的量化关系, 具体结果如表 5.1 所示。

表 5.1 数据集在不同基序保留比例下的 NMI 性能变化

数据集	高阶基序结构保留比例			
	100% (无掩码)	80%	60%	40%
Football	0.974	0.940	0.872	0.635
Cora	0.592	0.587	0.576	0.326
Citeseer	0.503	0.482	0.473	0.332

观察表中的数据可以发现, 在三个不同规模与特征的数据集上, 模型均展现出高度一致的非线性鲁棒性。以 Football 数据集为例, 当高阶基序保留比例从 100% (无掩码状态) 减至 60% 时, 其 NMI 值仅发生微小波动从 0.974 降至 0.872, 维持了较高的划分质量。Cora 与 Citeseer 数据集同样在剔除部分高阶结构后, 依然保持了良好的性能。

然而, 当保留比例进一步突破阈值极限 (如降至 40%) 时, 所有数据集的 NMI 值开始出现快速衰减。这一现象验证了: 网络中存在一个占比约 60% 的核心核心高阶基序结构; 而其余约 40% 的高阶连接则多为跨越真实边界的拓扑噪声或弱信息关联, 在量化层面验证了提取高阶基序结构的重要性与合理性。

当高阶掩码矩阵的优化过程收敛后, 保留下来的非零掩码权重直接反映了高阶拓扑在社区检测中的真实贡献度。为了更加直观地展示高阶基序的实际贡献, 本节以具有代表性的 Football 网络数据集为例进行可视化分析。本文通过设定阈值过滤掉掩码矩阵中接近于 0 的低贡献度结构, 仅保留权重较高的高阶网络骨架。如图

5.1 所示, 原始的 Football 网络拓扑结构较为复杂, 各支球队之间存在大量密集的交织连边, 社区的真实边界在低阶视图下不明显。




图 5.1 Football 原始图

经过互信息最大化与高阶掩码过滤后, 提取出的重要社区结构如图 5.2 所示。观察该可视化结果可以发现以下现象:




图 5.2 Football 中重要的高阶基序结构

(1) 原本错综复杂的全连接网络被清晰地解构为多个高度内聚的独立子结构。在这些保留下来的局部社区内部, 节点之间通过密集的三角形等多节点基序紧密交织, 形成了坚固的拓扑结构。

(2) 存在于原始图中的大量的松散连边通常不构成高阶基序被掩码机制赋予了 0 权重并剔除。

这一可视化分析结果从可解释性的角度，验证了 MAC 模型设计的高阶基序主导了局部紧密结构的识别。MAC 模型能够依托这些高阶结构锚定社区核心，克服了低阶弱关联边带来的拓扑噪声干扰，从而保障了社区划分的高度准确性。图 5.3 和图 5.4 分别展示了 Cora 和 Citeseer 数据集中重要的高阶结构。




图 5.3 Cora 中重要的高阶结构




图 5.4 Citeseer 中重要的高阶结构

5.2.2 基于掩码破坏机制的局部扩展结构依赖性分析

在 MAC 模型中, 为了克服传统局部社区检测算法中盲目扩展与种子质量评估的缺陷, 本文提出了一种基于三角基序的社区质量评价函数, 并以此为依据优先筛选高质量的种子社区进行联合约束扩展。然而, 这些三角基序结构在真实的局部社区扩展与边界确立过程中, 是否真正发挥了锚点作用。为了回答这一问题, 本节引入了基于最小化互信息反馈的扰动分析机制, 对局部种子扩展机制的结构依赖性进行分析。

与 5.2.1 节旨在寻找网络保留特征的最大化互信息策略不同, 本节旨在通过破坏性测试来分析三角基序的核心作用。传统的节点级扰动往往只能验证单个节点的重要性, 却忽略了网络的高阶拓扑语义。为此, 针对 MAC 模型在初始阶段筛选出的候选高质量种子社区 S , 本文没有使用简单的节点掩码, 而是构建了一个针对种子内部高阶结构的基序破坏掩码矩阵 M_{motif} 。

将该掩码作用于原始图拓扑中与核心种子相关的局部子图上, 即在保留种子节点不变的前提下, 遮蔽或切断构成三角基序的关键拓扑连接, 破坏其内部的高阶连接性。随后, 将经过结构扰动的图重新代入 MAC 模型的扩展模块中, 得到新的社区划分结果 $C_{perturb}$ 。

为了准确量化模型决策对高阶基序特征的依赖程度, 本节以最小化标准化互信息 NMI 为优化目标。优化过程的数学表达如下:


$$\min_{M_{motif}} NMI(C_{orig}, C_{perturb}) + \lambda \|1 - M_{motif}\|_1 \quad (5.3)$$

在上述公式中, C_{orig} 代表无掩码状态下的最优参考划分, λ 为正则化系数。该优化目标的物理意义在于: 寻找数量最少的核心基序连边进行破坏, 使得局部社区的后续扩展过程彻底偏离原始的正确边界, 导致前后划分结果的互信息降至最低。

为了验证高阶基序在扩展过程中的核心作用, 本文对被评价函数打出高分的核心种子社区逐步施加不同比例的基序结构掩码扰动, 并记录扰动后划分结果与原始最优划分之间的标准化互信息变化。

图 5.5 展示了核心种子内部高阶结构受损后的 NMI 变化曲线。结合图表数据

可以看出：即使核心种子的所有节点均未被删除，仅仅是按照极小的比例破坏了其内部的三角基序结构，局部社区后续的扩展结果也会发生偏移，导致 NMI 值出现下降。这一破坏性测试验证了主导局部社区稳健成型的，并非是孤立的节点实体，而是它们之间构成的三角高阶结构。这种模型性能对基序结构的高度敏感与强依赖性，验证了本文所提出的基于三角基序的社区质量评价函数的合理性。



(a) 在 Cora 上的实验结果

(b) 在 Citeseer 上的实验结果

图 5.5 Cora 数据集不同基序破坏比例下的标准化互信息

5.3 本章小结

本章针对深度图神经网络在局部社区检测任务中存在的难以解释的局限性，引入了一套基于掩码机制与互信息理论的可解释性分析方法。旨在从信息论的视角揭示 MAC 模型在社区划分与节点吸纳过程中的核心决策依据，从而提升模型在复杂网络应用中的透明度与可解释性。本章的主要工作与结论总结如下：

首先，针对 MAC 模型中高阶基序的实际贡献度问题，本章创新性地提出了一种基于掩码保留机制的高阶基序贡献分析方法。通过引入最大化标准互信息与稀疏正则化的优化策略，从错综复杂的网络中识别出了对社区划分具有决定性作用的核心拓扑骨架。量化分析与可视化验证结果表明：高阶基序在锚定局部社区的高内聚核心方面发挥了主导作用，模型依托这些高阶闭合结构能够有效识别社区边界并摒弃跨社区松散连边带来的拓扑噪声干扰。这一结论验证了 MAC 模型引入高阶基序以打破低阶成对连接局限、精准捕获节点间复杂协同交互的合理性。

其次，针对 MAC 模型的局部种子扩展机制，本章引入了基于最小化互信息反

馈的扰动分析方法，对局部扩展机制的结构依赖性进行了分析。破坏性掩码测试结果显示，即使仅对评价函数筛选出的高质量核心种子施加极小比例的高阶结构破坏，也会使得后续扩展轨迹发散，导致前后划分结果的互信息随之出现下跌。该现象揭示了高质量核心种子扩展对三阶基序结构的高度依赖，验证了核心高阶结构在指导局部社区稳健成型上的重要性。

综上所述，本章通过可视化与标准化互信息指标，探讨了高阶拓扑特征对社区划分的影响。借助标准化互信息的最大化与最小化分析，本章不仅验证了高阶基序结构对锚定社区的核心支撑作用，也凸显了基于三角基序的评价函数在规避种子社区扩展发散上的重要性。这使得本文所构建的方法在兼顾高划分精度的同时，展现出良好的可解释性，验证了引入高阶基序与设计三角基序扩展指导函数的合理性。

第6章 总结与展望

6.1 总结

自然界与人类社会中存在的众多复杂系统如社交网络、引文网络和生物网络等均可抽象为复杂网络进行建模分析。社区检测作为揭示网络内部组织规律与隐藏特征的核心技术，在推荐系统和异常检测等领域具有很高的应用价值。传统的全局社区检测算法在应对大规模网络时难以兼顾社区检测精度，而新兴的局部社区检测算法虽然提高了效率，但在种子社区构建和扩展过程中仍面临诸多挑战：一方面，现有方法未充分利用节点的高维属性信息构建初始种子社区，且常常将种子社区视为孤立实体，忽视了种子社区之间的连接关系导致过度分割；另一方面，现有方法往往依赖于低阶的拓扑连接难以捕捉网络中的高阶协同关系，引入高阶结构时又容易过度依赖高阶结构的出现频率，缺少对种子社区质量的评估，不能实现差异化的种子社区扩展，导致社区扩展偏向于密集核心区域的核心偏置现象。针对上述复杂网络中局部社区检测面临的问题，本文研究了图对比学习与高阶拓扑语义的融合方法，提出了 CSSGCL 方法和 MAC 方法。具体研究工作总结如下：

首先，针对传统种子生成方法导致的过度分割与未充分使用属性生成种子社区的问题，本文提出了一种基于连通种子结构和图对比学习的社区检测方法 CSSGCL。该方法首先引入变分图自编码器对网络拓扑进行增强重构，将节点间的属性相关性映射到拓扑连接中，过滤噪声边并添加了潜在连接关系。在增强图的基础上，该方法利用极大 k -plex 结构提取内部紧密连接的孤立种子社区，同时完整保留种子社区之间的连接关系，以构建具有全局视野的连通种子社区。随后，通过设计双视图图对比学习框架，在统一的潜在空间中对齐并融合了孤立与连通种子社区信息，实现了相似种子的合并。最后，通过标签传播算法完成剩余节点的精准分配。在 12 个不同领域的真实世界网络数据集上的实验验证了 CSSGCL 的有效性。

其次，针对现有方法在捕捉网络高阶协同信息方面的不足以及种子质量评估缺失的问题，本文进一步提出了一种基于基序感知和图对比学习的社区检测方法

MAC。该方法克服了成对边连接的局限性，通过提取三阶与四阶基序并剔除嵌套冗余，创新性地构建了高阶超图结构。为了同时保留低阶特征并融合高阶语义，MAC 设计了包含图卷积与超图卷积的高低阶双通道编码框架，并通过图对比学习实现多层次拓扑语义的对齐与融合。此外，针对种子扩展过程，本文将模块度思想推广至高阶层面，提出了一种基于三角基序的社区质量评价函数，并在扩展过程中实施基于基序结构约束与特征一致性的联合策略，指导社区向着结构更稳健的方向扩展。在 7 个复杂属性网络上的实验表明，MAC 在 NMI、F1 及高阶基序评价指标上取得了性能优势，验证了融合高低阶特征在提升局部社区检测质量方面的巨大潜力。

最后，针对社区检测模型的难以解释的问题，本文构建了基于掩码机制与互信息理论的可解释性分析方法。一方面，通过掩码保留机制提炼出社区核心高阶结构，验证了高阶基序在锚定社区核心的主导作用；另一方面，通过掩码破坏扰动测试，揭示了社区扩展对三角基序结构的高度依赖，验证了本文所提基于三角基序的种子社区扩展指导函数的合理性。

6.2 展望

本文在结合图神经网络、图对比学习以及高阶基序特征进行复杂网络局部社区检测方面进行了探索，但在实际应用与模型优化上仍存在一些值得进一步改进的空间：

(1) 稀疏网络下的高阶结构建模。本文通过基序构建超图的方法在提取高阶信息方面表现优异，但在极端稀疏的网络环境中，寻找高阶基序变得极具挑战性，这会导致构建的超图连通性较差，进而限制超图神经网络的有效性。未来的研究可考虑引入图生成模型或边预测技术，通过有效利用合成数据或生成潜在的基序来增强稀疏网络的拓扑表达，从而提高模型在数据匮乏场景下的鲁棒性。

(2) 更高阶超边的动态构建与自适应权重。本文主要利用三阶和四阶基序来构建超图，缺乏对其他类型基序比如星型基序的探索，这在一定程度上限制了模型捕获复杂宏观结构的能力。未来的工作可以探究如何高效挖掘其他类型的网络基序，并设计自适应的注意力机制，使模型能够根据不同网络的拓扑特性，自动学习并动

态调节低阶通道与各种高阶通道之间的特征融合权重。

(3) 面向动态演化网络的局部社区检测。本文目前主要针对静态网络的社区检测展开研究。然而,现实世界中的网络往往是随时间动态演化的。未来可以探索将时序图神经网络或动态超图卷积引入当前的对比学习框架中,使得种子社区能够随着网络拓扑的时间演变而进行自适应的动态更新与边界演化,从而实现实时、增量式的高精度的社区检测。

参考文献

- [1] 安沈昊,于荣欢.复杂网络理论研究综述[J].计算机系统应用,2020,29(09):26-31.
- [2] 刘涛,陈忠,陈晓荣.复杂网络理论及其应用研究概述[J].系统工程,2005,(06):1-7.
- [3] Girvan M, Newman ME J. Community structure in social and biological networks[J]. Proceedings of the national academy of sciences, 2002, 99(12): 7821-7826.
- [4] Yang B, Liu D, Liu J. Discovering communities from social networks: Methodologies and applications[M]//Handbook of social network technologies and applications. Springer, New York, NY, 2010: 331-346.
- [5] Stodt F, Reich C, Theoleyre F. Context-aware anomaly detection by community detection in the Internet of Things[J]. Computer Communications, 2026: 108414.
- [6] De Montis A, Barthélemy M, Chessa A, et al. The structure of interurban traffic: a weighted network analysis[J]. Environment and Planning B: Planning and Design, 2007, 34(5): 905-924.
- [7] Jiang R, Yang R, Lin W. Community-Aware Social Community Recommendation[C]//Proceedings of the 34th ACM International Conference on Information and Knowledge Management. 2025: 1179-1189.
- [8] Blondel V D, Guillaume J L, Lambiotte R, et al. Fast unfolding of communities in large networks[J]. Journal of statistical mechanics: theory and experiment, 2008, 2008(10): P10008.
- [9] Garza S E, Schaeffer S E. Community detection with the label propagation algorithm: a survey[J]. Physica A: Statistical Mechanics and its Applications, 2019, 534: 122058.
- [10] Ng A, Jordan M, Weiss Y. On spectral clustering: Analysis and an algorithm[J]. Advances in neural information processing systems, 2001, 14.
- [11] Fortunato S, Barthelemy M. Resolution limit in community detection[J]. Proceedings of the national academy of sciences, 2007, 104(1): 36-41.
- [12] Luo W, Zhang D, Ni L, et al. Multiscale local community detection in social networks[J]. IEEE Transactions on Knowledge and Data Engineering, 2019, 33(3): 1102-1112.
- [13] 史艳翠,王嫻,赵青,等.基于局部扩展的社区发现研究现状[J].通信学报,2019,40(01):149-162.
- [14] 聂世民,杜彦辉,芦天亮,等.局部社区发现算法研究综述[J].软件导刊,2020,19(05):271-275.
- [15] Luo D, Bian Y, Yan Y, et al. Local community detection in multiple networks[C]//Proceedings of the 26th ACM SIGKDD international conference on knowledge discovery & data mining. 2020: 266-274.
- [16] Su X, Xue S, Liu F, et al. A comprehensive survey on community detection with deep learning[J].

- IEEE transactions on neural networks and learning systems, 2022, 35(4): 4682-4702.
- [17] Jiang G, Chen J, Peng Z, et al. Graph contrastive high-order structure representation learning[J]. Neurocomputing, 2025: 132566.
- [18] 冯拓宇,刘佳宁,曹子奇,等.社区发现方法研究综述[J].中国电子科学研究院学报,2024,19(06): 487-498+503.
- [19] Jin D, Yu Z, Jiao P, et al. A survey of community detection approaches: From statistical modeling to deep learning[J]. IEEE Transactions on knowledge and data engineering, 2021, 35(2): 1149-1170.
- [20] Dutt S. New faster kernighan-lin-type graph-partitioning algorithms[C]//Proceedings of 1993 International Conference on Computer Aided Design (ICCAD). IEEE, 1993: 370-377.
- [21] Shi J, Malik J. Normalized cuts and image segmentation[J]. IEEE Transactions on pattern analysis and machine intelligence, 2000, 22(8): 888-905.
- [22] Traag V A, Waltman L, Van Eck N J. From Louvain to Leiden: guaranteeing well connected communities[J]. Scientific reports, 2019, 9(1): 5233.
- [23] Rosvall M, Bergstrom C T. Maps of random walks on complex networks reveal community structure[J]. Proceedings of the national academy of sciences, 2008, 105(4): 1118-1123.
- [24] Good B H, De Montjoye Y A, Clauset A. Performance of modularity maximization in practical contexts[J]. Physical Review E—Statistical, Nonlinear, and Soft Matter Physics, 2010, 81(4): 046106.
- [25] Baltso G, Christopoulos K, Tsihlias K. Local community detection: A survey[J]. IEEE Access, 2022, 10: 110701-110726.
- [26] Clauset A, Newman M E J, Moore C. Finding community structure in very large networks[J]. Physical Review E—Statistical, Nonlinear, and Soft Matter Physics, 2004, 70(6): 066111.
- [27] Liu M, Yang J, Guo J, et al. A label propagation community discovery algorithm combining seed node influence and neighborhood similarity[J]. Knowledge and Information Systems, 2024, 66(4): 2625-2649.
- [28] Zhu J, Chen B, Zeng Y. Community detection based on modularity and k-plexes[J]. Information Sciences, 2020, 513: 127-142.
- [29] Spielman D A, Teng S H. A local clustering algorithm for massive graphs and its application to nearly linear time graph partitioning[J]. SIAM Journal on computing, 2013, 42(1): 1-26.
- [30] Das S, Devarapalli R K, Biswas A. Leveraging cascading information for community detection in social networks[J]. Information Sciences, 2024, 674: 120696.
- [31] Wang Z Y, Zhang C P, Yahya R O. High-quality community detection in complex networks based on node influence analysis[J]. Chaos, Solitons & Fractals, 2024, 182: 114849.

-
- [32] Perozzi B, Al-Rfou R, Skiena S. Deepwalk: Online learning of social representations[C]// Proceedings of the 20th ACM SIGKDD international conference on Knowledge discovery and data mining. 2014: 701-710.
 - [33] Corso G, Stark H, Jegelka S, et al. Graph neural networks[J]. Nature Reviews Methods Primers, 2024, 4(1): 17.
 - [34] Jin D, Liu Z, Li W, et al. Graph convolutional networks meet markov random fields: Semi-supervised community detection in attribute networks[C]//Proceedings of the AAAI conference on artificial intelligence. 2019, 33(01): 152-159.
 - [35] Chen L, Zhou Q, Zhao D. k-plex-based community detection with graph neural networks[J]. Information Sciences, 2025, 689: 121509.
 - [36] Li P Z, Huang L, Wang C D, et al. EdMot: An edge enhancement approach for motif-aware community detection[C]//Proceedings of the 25th ACM SIGKDD international conference on knowledge discovery & data mining. 2019: 479-487.
 - [37] Wu X, Wang C D, Lin J Q, et al. Motif-based contrastive learning for community detection[J]. IEEE Transactions on Neural Networks and Learning Systems, 2024, 35(9): 11706-11719.
 - [38] Feng Y, You H, Zhang Z, et al. Hypergraph neural networks[C]//Proceedings of the AAAI conference on artificial intelligence. 2019, 33(01): 3558-3565.
 - [39] Bai S, Zhang F, Torr P H S. Hypergraph convolution and hypergraph attention[J]. Pattern Recognition, 2021, 110: 107637.
 - [40] Kang X, Li X, Yao H, et al. Dynamic hypergraph neural networks based on key hyperedges[J]. Information Sciences, 2022, 616: 37-51.
 - [41] Newman M E J, Girvan M. Finding and evaluating community structure in networks[J]. Physical review E, 2004, 69(2): 026113.
 - [42] Liu L, Xu L, Wang Y Z, et al. Community detection based on structure and content: A content propagation perspective[C]//2015 IEEE international conference on data mining. IEEE, 2015: 271-280.
 - [43] Yang J, McAuley J, Leskovec J. Community detection in networks with node attributes[C]//2013 IEEE 13th international conference on data mining. IEEE, 2013: 1151-1156.
 - [44] Wu L, Cui P, Pei J, et al. Graph neural networks: foundation, frontiers and applications [C]//Proceedings of the 28th ACM SIGKDD conference on knowledge discovery and data mining. 2022: 4840-4841.
 - [45] Kipf T N, Welling M. Semi-supervised classification with graph convolutional networks[J]. arXiv preprint arXiv:1609.02907, 2016.
 - [46] Zhang H, Li P, Zhang R, et al. Embedding graph auto-encoder for graph clustering[J]. IEEE

- Transactions on Neural Networks and Learning Systems, 2022, 34(11): 9352-9362.
- [47] Kipf T N, Welling M. Variational graph auto-encoders[J]. arXiv preprint arXiv:1611.07308, 2016.
- [48] Veličković P, Fedus W, Hamilton W L, et al. Deep graph infomax[J]. arXiv preprint arXiv:1809.10341, 2018.
- [49] You Y, Chen T, Sui Y, et al. Graph contrastive learning with augmentations[J]. Advances in neural information processing systems, 2020, 33: 5812-5823.
- [50] Zhu Y, Xu Y, Yu F, et al. Graph contrastive learning with adaptive augmentation[C]//Proceedings of the web conference 2021. 2021: 2069-2080.
- [51] Milo R, Shen-Orr S, Itzkovitz S, et al. Network motifs: simple building blocks of complex networks[J]. Science, 2002, 298(5594): 824-827.
- [52] Shang R, Zhang W, Zhang J, et al. Local community detection based on higher-order structure and edge information[J]. Physica A: Statistical Mechanics and its Applications, 2022, 587: 126513.
- [53] Fu K, Yan G, Luo H, et al. Research on a link prediction algorithm based on hypergraph representation learning[J]. Electronics, 2023, 12(23): 4842.
- [54] Xiao M, Lin W, Dai Y, et al. A fast algorithm to compute maximum k-plexes in social network analysis[C]//Proceedings of the AAAI conference on Artificial Intelligence. 2017, 31(1).
- [55] Aral S, Walker D. Identifying influential and susceptible members of social networks[J]. Science, 2012, 337(6092): 337-341.
- [56] Zachary W W. An information flow model for conflict and fission in small groups[J]. Journal of anthropological research, 1977, 33(4): 452-473.
- [57] Newman M E J. Finding community structure in networks using the eigenvectors of matrices[J]. Physical Review E—Statistical, Nonlinear, and Soft Matter Physics, 2006, 74(3): 036104.
- [58] Tang J, Zhang J, Yao L, et al. Arnetminer: extraction and mining of academic social networks[C]//Proceedings of the 14th ACM SIGKDD international conference on Knowledge discovery and data mining. 2008: 990-998.
- [59] Pei H, Wei B, Chang K C C, et al. Geom-gcn: Geometric graph convolutional networks[J]. arXiv preprint arXiv:2002.05287, 2020.
- [60] Yang Z, Cohen W, Salakhudinov R. Revisiting semi-supervised learning with graph embeddings[C]//International conference on machine learning. PMLR, 2016: 40-48.
- [61] Munkres J. Algorithms for the assignment and transportation problems[J]. Journal of the society for industrial and applied mathematics, 1957, 5(1): 32-38.
- [62] Grover A, Leskovec J. node2vec: Scalable feature learning for networks[C]//Proceedings of the 22nd ACM SIGKDD international conference on Knowledge discovery and data mining. 2016: 855-864.

- [63] Wang X, Li J, Yang L, et al. Unsupervised learning for community detection in attributed networks based on graph convolutional network[J]. *Neurocomputing*, 2021, 456: 147-155.
- [64] Lee N, Lee J, Park C. Augmentation-free self-supervised learning on graphs[C]//*Proceedings of the AAAI conference on artificial intelligence*. 2022, 36(7): 7372-7380.
- [65] Chen H, Zhao Z, Li Y, et al. CSGCL: community-strength-enhanced graph contrastive learning[J]. *arXiv preprint arXiv:2305.04658*, 2023.
- [66] Clauset A. Finding local community structure in networks[J]. *Physical Review E—Statistical, Nonlinear, and Soft Matter Physics*, 2005, 72(2): 026132.
- [67] Kloumann I M, Kleinberg J M. Community membership identification from small seed sets[C]//*Proceedings of the 20th ACM SIGKDD international conference on Knowledge discovery and data mining*. 2014: 1366-1375.
- [68] Lee C, Reid F, McDaid A, et al. Detecting highly overlapping community structure by greedy clique expansion[J]. *arXiv preprint arXiv:1002.1827*, 2010.
- [69] Paredes P, Ribeiro P. Rand-fase: fast approximate subgraph census[J]. *Social Network Analysis and Mining*, 2015, 5(1): 17.
- [70] Rozemberczki B, Allen C, Sarkar R. Multi-scale attributed node embedding[J]. *Journal of Complex Networks*, 2021, 9(2): cnab014.
- [71] Veličković P, Cucurull G, Casanova A, et al. Graph attention networks[J]. *arXiv preprint arXiv:1710.10903*, 2017.
- [72] Chen X, Cai R, Fang Y, et al. Motif graph neural network[J]. *IEEE Transactions on Neural Networks and Learning Systems*, 2023, 35(10): 14833-14847.
- [73] Li P Z, Huang L, Wang C D, et al. Community detection by motif-aware label propagation[J]. *ACM Transactions on Knowledge Discovery from Data (TKDD)*, 2020, 14(2): 1-19.
- [74] Benson A R, Gleich D F, Leskovec J. Higher-order organization of complex networks[J]. *Science*, 2016, 353(6295): 163-166.
- [75] Bai S, Zhang F, Torr P H S. Hypergraph convolution and hypergraph attention[J]. *Pattern Recognition*, 2021, 110: 107637.

致 谢

三年的研究生生活如白驹过隙，转瞬即逝。此时此刻，站在三年硕士生涯的终点回首望去，凤凰花开花落已伴我走过了七个春秋。四载本科的青春求索与三载硕士的科研淬炼，共同织就了我在母校最珍贵的七年岁月。在论文定稿之际，感怀万千，谨以此寥寥数语，致谢那些在我生命中留下深刻印迹的人与事。

首先，我要由衷地感谢我的导师***，“落其实者思其树，饮其流者怀其源”。*老师不仅在学术上给予了我悉心的指导，更在生活上对我关怀备至。她严谨治学的态度、敏锐的学术洞察力以及对科研工作的热爱，深深地感染并激励着我。能够师从*老师，是我硕士生涯最大的荣幸。

其次，我要感谢在科研与生活中并肩同行实验室伙伴们。感谢**等人在科研讨论中的无私分享。感谢同窗好友**在学业上的相互支持；感谢良友**在枯燥的科研生活之余，给予了我生活上的关怀与鼓励。

同时，我要感谢我的家人，你们永远是最坚实的后盾，给予了我无条件的爱与信任。正是因为有你们的理解与支持，我才能心无旁骛地投入到研究中。特别感谢我的姐姐，在我求学的过程中，你始终支持着我，不仅在生活上给予我支持，也在我感到压力与迷茫时耐心倾听、不断鼓励。你为我分担了许多学业之外的压力，让我能够更加专注于自己的目标与方向。这份陪伴与付出，我始终铭记于心。

最后，我要感谢厦门大学，为我提供了广阔的求知平台与浓厚的治学氛围。在这座美丽的校园里，我不仅充实了专业知识，更在潜移默化中塑造了正确的世界观、人生观与价值观，领悟了自强不息、止于至善的真谛。

在学期间完成的相关学术成果

学术论文:

- [1] ***, ***, ***, et.al. *****[C]//7th China Symposium on Cognitive Computing and Hybrid Intelligence (CCHI). IEEE, 2025. (第一作者)
- [2] ***, ***, ***, et.al. *****[J]. Information Sciences, 2025, ***. (第二作者)